第3回プログラミングゼミ

確率密度関数・累積分布関数

M1 徳本大輝

2023/05/10

第3回の目標

Part1：

Pandas, Matplotlibの使い方に慣れる

Part2：

確率密度関数・累積分布関数(PDF・CDF)を理解し、自分で描画できる

Part1：Pythonライブラリの紹介

(Pandas, Matplotlib)

Pandas

特徴

・Series型が集まったもので、二次元データを扱える（DataFrame）

・行（index）と列（columns）をそれぞれ指定することでデータを取得、集計、加工できる

・Numpyとは異なり、数値だけではなく、文字列などの様々なデータ型を扱うことが可能

・データ分析、機械学習、ディープラーニングには必要不可欠

```python
import pandas as pd

# DataFrameとしてcsvを読み込む
data = pd.read_csv("kanazawa2017-2019_utf8.csv")
data
```

columns

index

	年月日時	気温(°C)	降水量(mm)	風速(m/s)	風速(m/s).1	積雪(cm)	降雪(cm)	現地気圧(hPa)
0	2017/1/1 1:00	7.5	0.5	5.9	南南西	0.0	0.0	1020.4
1	2017/1/1 2:00	7.4	0.0	5.6	南南西	0.0	0.0	1020.6
2	2017/1/1 3:00	6.8	0.5	4.4	南南西	0.0	0.0	1020.8
3	2017/1/1 4:00	6.3	2.5	0.9	南南西	0.0	0.0	1020.7
4	2017/1/1 5:00	5.9	2.0	3.7	南	0.0	0.0	1021.2
...	...	...	...	...	...	...	...	...
26275	2019/12/31 20:00	3.4	0.0	3.2	北	0.0	0.0	1022.4
26276	2019/12/31 21:00	2.8	0.5	3.4	西北西	0.0	0.0	1022.4
26277	2019/12/31 22:00	2.4	0.0	2.0	西	0.0	0.0	1022.7
26278	2019/12/31 23:00	2.5	0.0	3.0	南東	0.0	0.0	1022.4
26279	2020/1/1 0:00	2.0	0.0	3.0	東	0.0	0.0	1022.3

26280 rows × 8 columns

Matplotlib

特徴

・グラフの描画やデータの可視化が簡単に可能

・図の作り方は主に2通り

1. pyplotモジュールを使用
2. オブジェクト指向で書く(ax)

→ 簡単に書ける1を行う

流れ

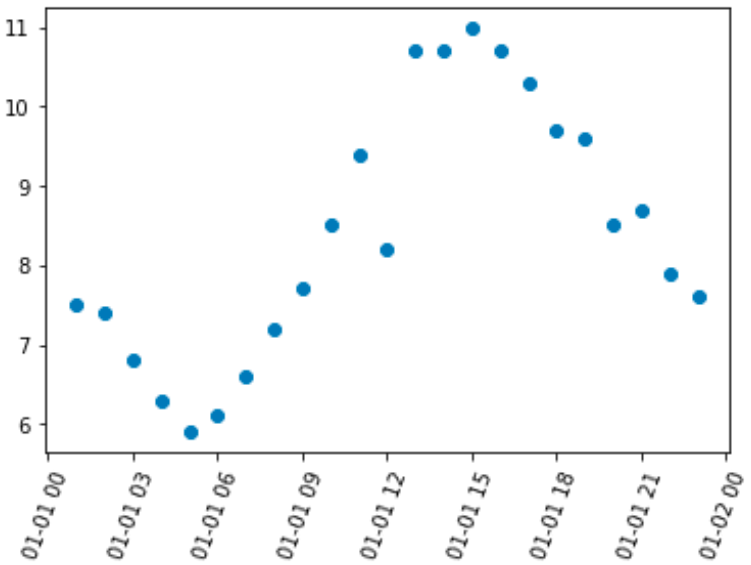
1. pyplotをimport
2. plt.plotでグラフを描画
3. plt.XXX()でグラフ内要素を追加

```
## 2017/01/01における気温の変化
import pandas as pd
import matplotlib.pyplot as plt


data = pd.read_csv("kanazawa2017-2019_utf8.csv")
x = pd.to_datetime(data["年月日時"])
y = data["気温(℃)"]

plt.xticks(rotation=70)
plt.scatter(x[0:23], y[0:23])
plt.show()
```

描画例



課題1：データ可視化

(1) 金沢の気温データの2017/1/1から72時間分のデータをx軸ラベル、y軸ラベル、
　　タイトルをつけ、折れ線でplot
ヒント：plt.title, plt.xlabel, plt.ylabel
横軸の範囲に注意

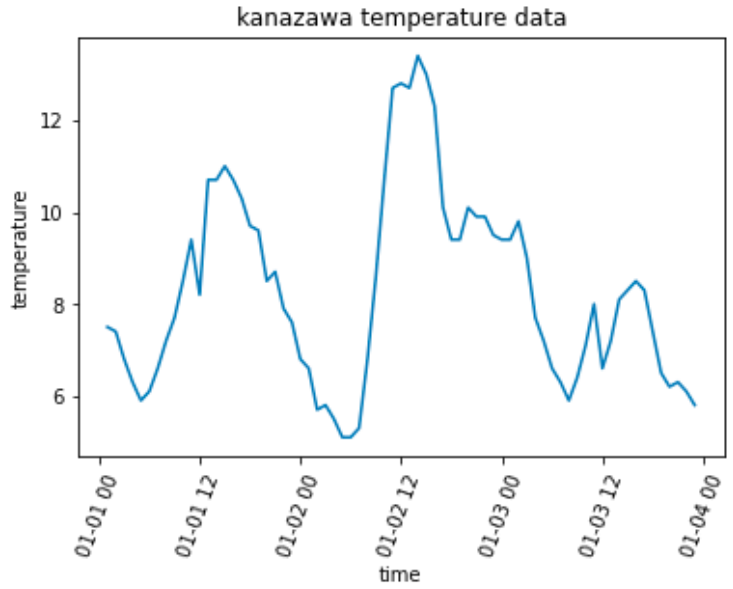
(2) (1)を散布図でplot

(3) (1)を棒グラフでplot

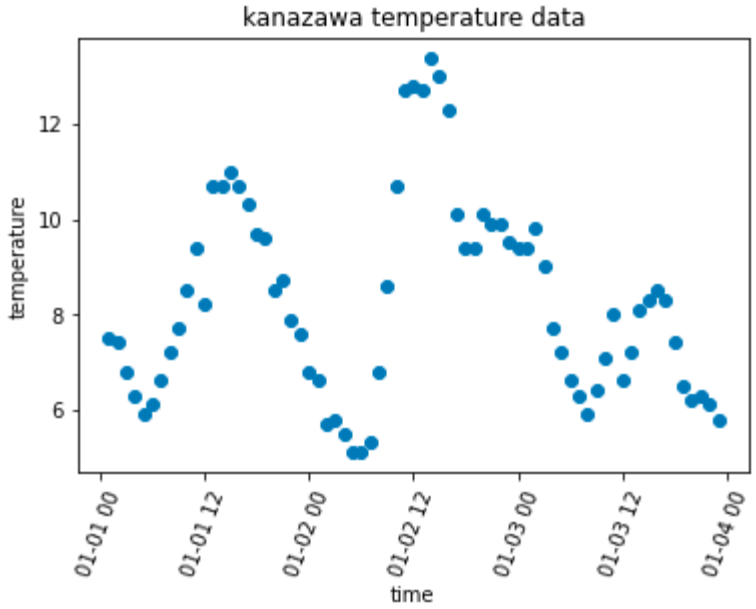
(4) 2017/1/1~1/3までの3日分のデータを24時間の範囲で重ねてプロット
横軸：0時-23時

課題1：正解例

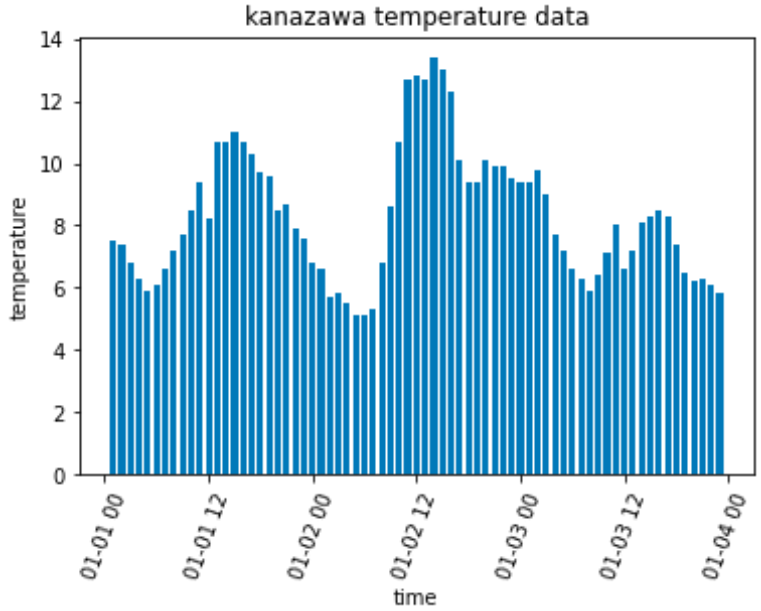
(1)


kanazawa temperature data
temperature
time
01-01 00
01-01 12
01-02 00
01-02 12
01-03 00
01-03 12
01-04 00

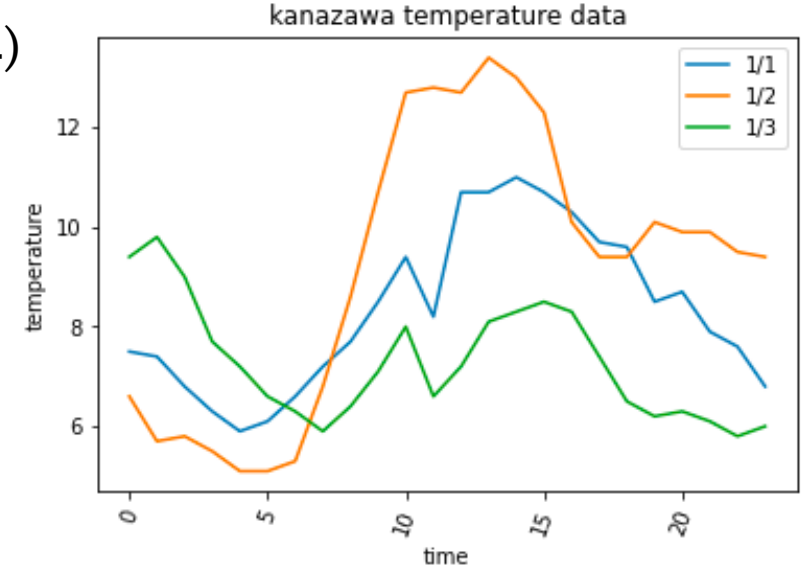
(2)


kanazawa temperature data
temperature
time
01-01 00
01-01 12
01-02 00
01-02 12
01-03 00
01-03 12
01-04 00

(3)


kanazawa temperature data
temperature
time
01-01 00
01-01 12
01-02 00
01-02 12
01-03 00
01-03 12
01-04 00

(4)


kanazawa temperature data
1/1
1/2
1/3
temperature
time

Part2：確率密度関数・累積分布関数

(PDF・CDF)

確率密度関数と累積分布関数

一般的な定義（PDF）

$$P(a < X < b) = \int_a^b f(x)dx$$

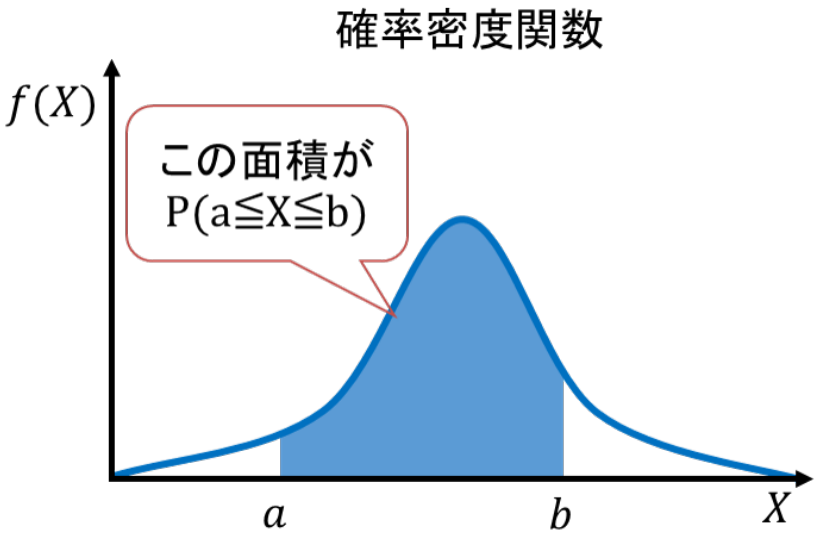
一般的な定義（CDF）

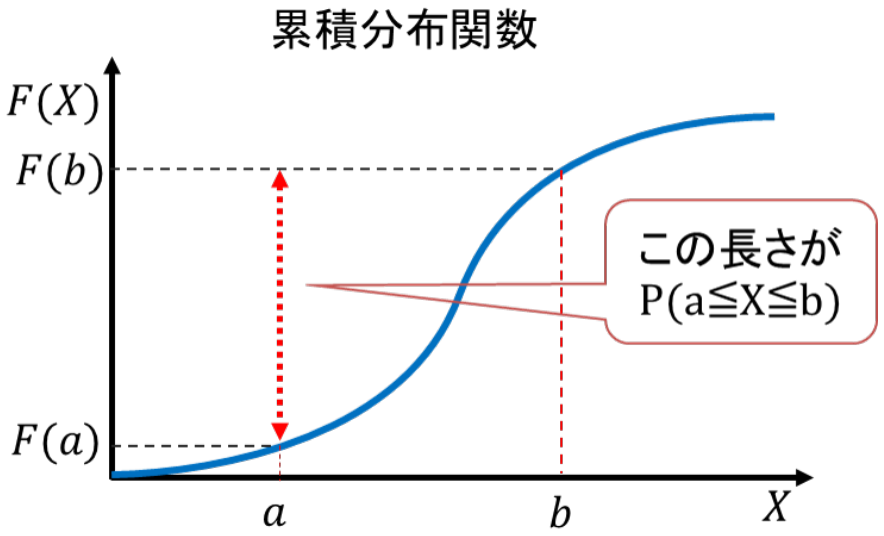
$$F(x) = P(X < x) = \int_{-\infty}^{x} f(x')dx'$$

高安研の定義（CDF）

$$F(x) = P(X > x) = \int_x^{\infty} f(x')dx'$$

一般的なCDFは小さな値から（左から）積分
高安研版は大きな値から（右から）積分





https://bellcurve.jp/statistics/course/6710.html

確率密度関数(PDF)

PDFの定義は連続関数である。今回はそれを離散的なデータから推定する

ヒストグラム法を用いた確率密度関数の推定

ヒストグラム法の流れ

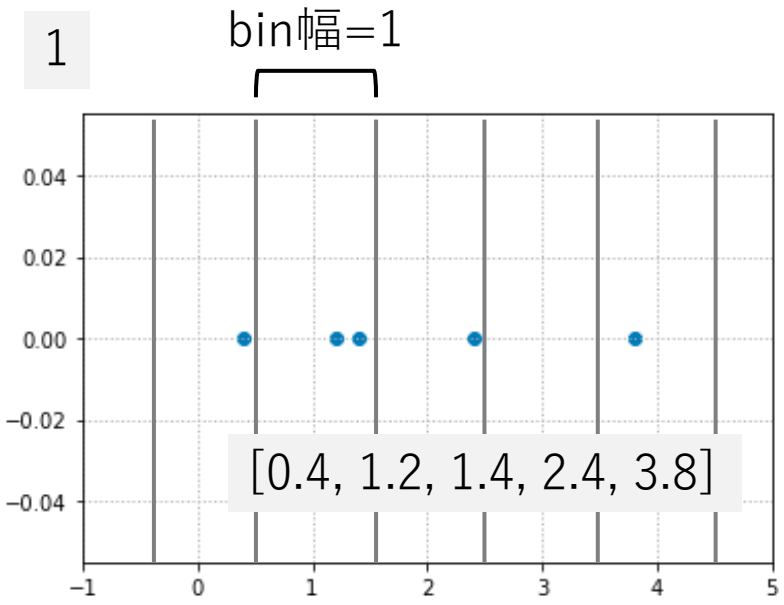
1. データをbin幅を決める
2. 各binにおけるデータ数をカウント
   （これをプロットするとヒストグラム）
3. データ総数で割ってプロット（正規化）

PDFを描く上での注意点

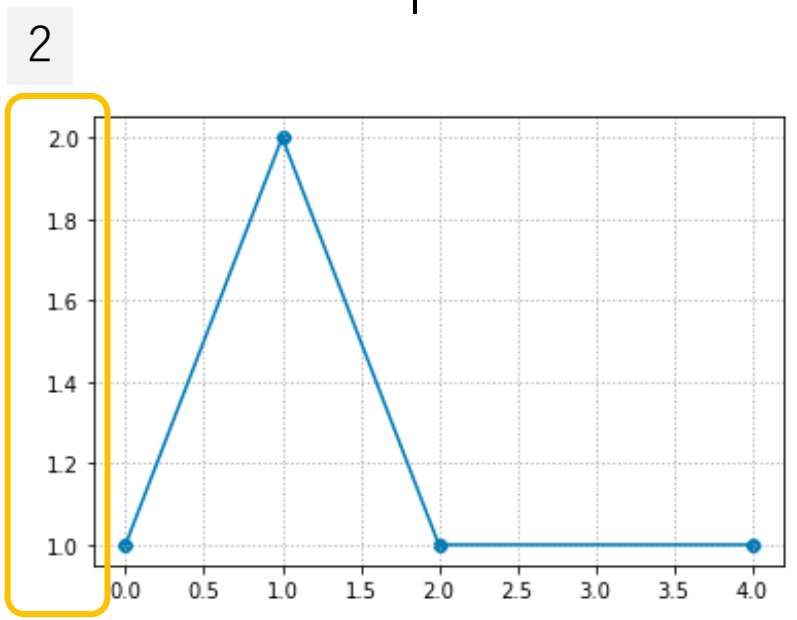
・全ての面積を足すと1

・値の丸め方とプロットするx方向の位置
（四捨五入か切り捨てか。下の例は四捨五入で丸めている）

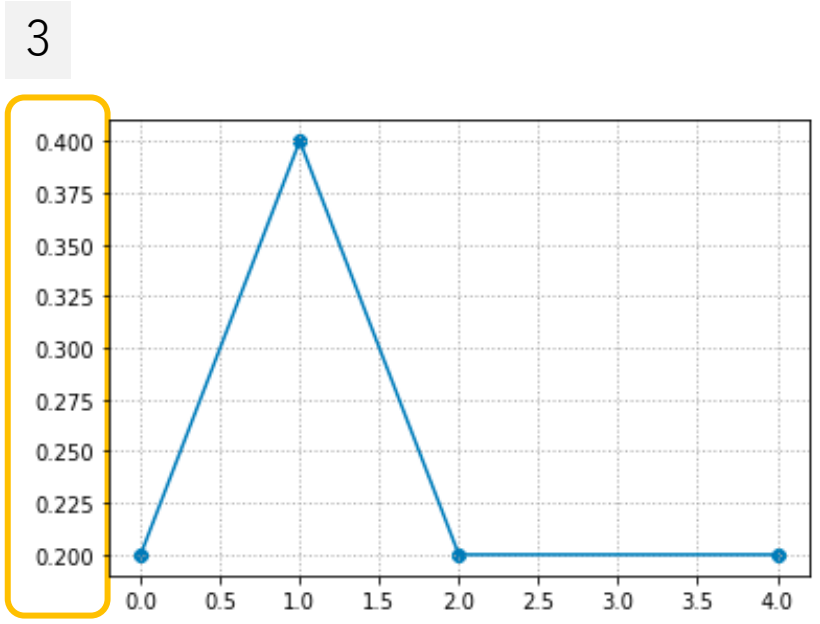
1



2



3



累積分布関数(CDF)

・PDFを積分したもの

・各確率の累積

・高安研では右を使用

→ べき分布を観測しやすくするため

高安研の定義（CDF）

$$F(x) = P(X > x) = \int_x^{\infty} f(x')dx'$$

べき分布

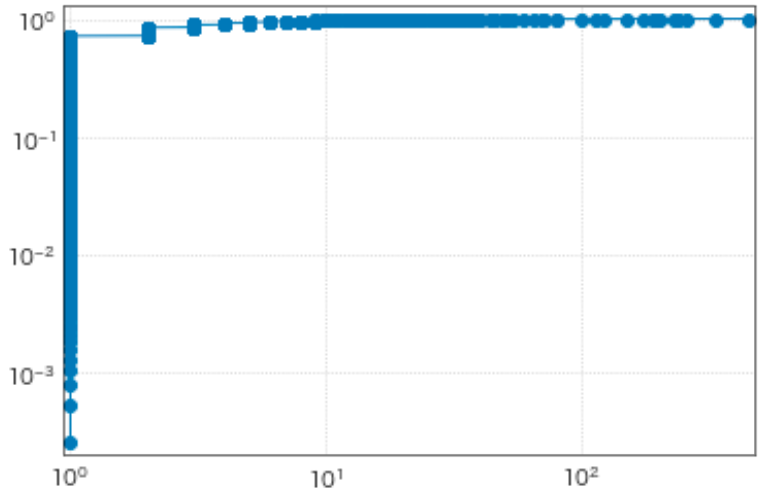
・極端な値をとるサンプルの数が正規分布より多い

・両対数軸で直線

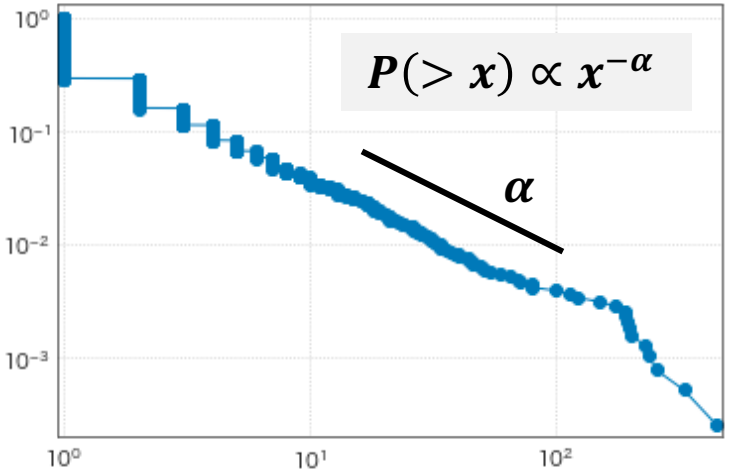
ex) 株価、為替などの市場価格の変動、地震の大きさと発生頻度 etc

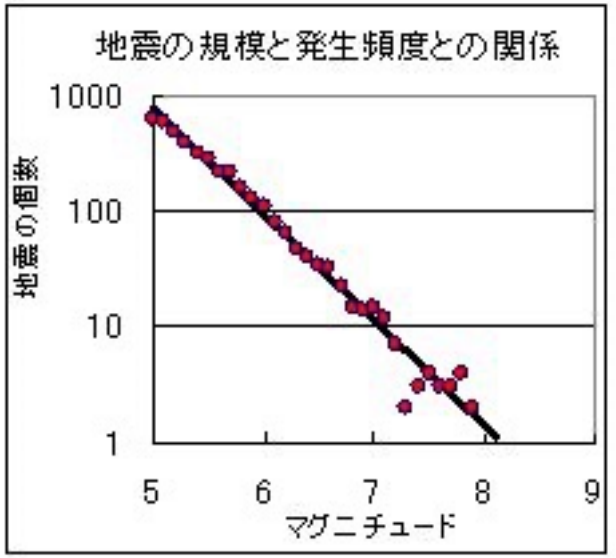
PDF：$f(x) = cx^{-(\alpha+1)}$ $(x > 0)$
CDF：$P(> x) \propto x^{-\alpha}$ $(x > 0)$

通常のCDF（左から積分）



高安研のCDF（右から積分）





https://yunavi.lsv.jp/powerlaw.html

課題2：確率密度関数(PDF)・累積分布関数(CDF)

1. 全時系列において、気温の確率密度関数(PDF)を作成
   （Bin幅=1と0.5の2つ, 値の丸め方は切り捨て）

2. 全時系列において、気温の累積分布関数(CDF)を作成
   （高安研版）

3. python_wiki_words.csvを用いて、単語の出現頻度のCDFを両対数軸で描画

Advanced

4. python_wiki_words.csvを用いて、単語の出現頻度のPDFを横軸logスケールで描画

PDF作成の方針

1. ビン幅、ビンのスタート地点を決定
2. そのビン幅における必要なビン数を計算
3. 値の丸め方を決定し、丸める
4. 丸めたときのビンの値、そのビン幅に存在するデータ数のカウントを、辞書型配列(dict)のkeyとvalueにそれぞれ格納
5. valueの格納した値を全てvalueの合計値で割る
6. 横軸にkey, 縦軸に5のvalueをプロット

CDF作成の方針

・右から積分というのをプログラミングでどう表現するか

PDFの横軸logスケールの方針

・データ自体にlogを適用させる
・x軸にプロットされる配列をlog対応にする（10の乗数）

ヒント1

dict = {key : value}

具体例

データ = [0.4, 1.2, 1.4, 2.4, 3.8]

これを四捨五入で丸めたときのビンの値、ビン幅に存在するデータ数のカウントは以下の通り

dict = {0:1, 1:2, 2:1, 4:1}

例えばdict={0:1}は、0の要素が1つあるという意味

ヒント2

四捨五入で丸めたときと、切り捨てで丸めたときのデータの集約の仕方に注意