

プログラミングゼミ2023
統計量とべき分布

志田洋平

今日のプログラミングゼミについて

Tokyo Tech

今日のゴール

べき分布の基本的な特性について理解し，

要約特徴量の計算，適切なPDF,CDFの計算が行えるようになる

（余裕があればいくつかの生成モデル，べき分布検定を知る）

必要な知識

基礎的な統計知識（院試が解けるレベル）

目次

べき分布の基本的な特性

- モーメントの発散
- 一般化中心極限定理
- 平均分散に代わる要約統計量

べき分布生成メカニズムと現象への当てはめ

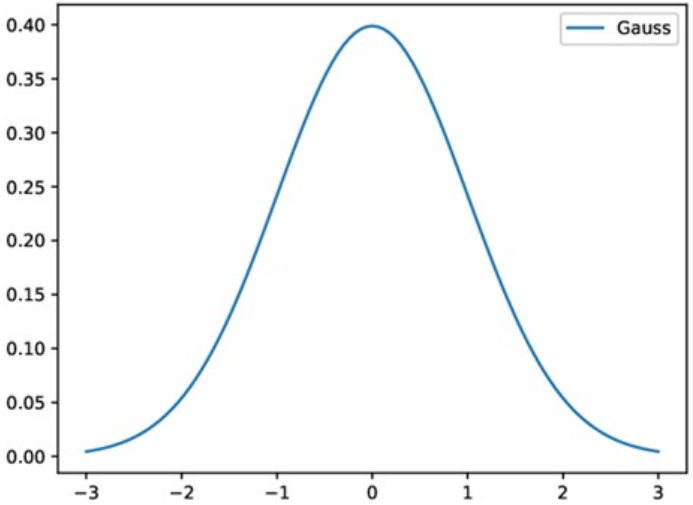
- 単語の出現頻度（指数分布と指数成長の組み合わせ）
- 生物の属の数と属が含む種の数の関係（Yule過程）

分布の特徴付け

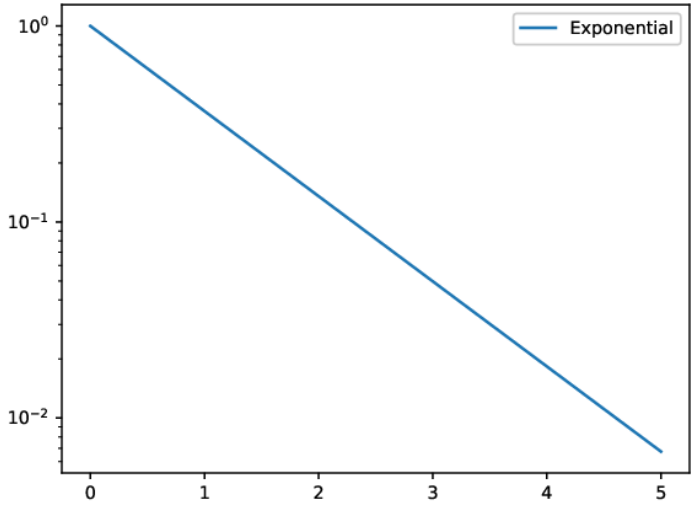
普通の分布を見たら

平均・分散などを計算する

正規分布



指数分布



正規分布は通常の線形軸

指数分布は片対数軸であることに注意

分布の特徴付け

n次の中心モーメント

$$\langle (x-\mu)^n \rangle \equiv \int_{-\infty}^{\infty} (x-\mu)^n f(x) dx$$

- 平均　$\mu \equiv \int_{-\infty}^{\infty} x f(x) dx$
- 分散　$\sigma^2 \equiv \langle (x-\mu)^2 \rangle$
- 歪度　$s \equiv \langle (x-\mu)^3 \rangle / \sigma^3$
- 尖度　$k \equiv \langle (x-\mu)^4 \rangle / \sigma^4 - 3$

正規分布で$s = k = 0$となるように定義

正規分布より歪んでいるか

尖っているか

今日扱うのはモーメントが使えない分布

モーメントが使えない確率分布

べき分布

$$f(x) = \frac{\alpha}{x_{min}^{-\alpha}} x^{-(\alpha+1)}, \qquad x \in [x_{min}, \infty)$$

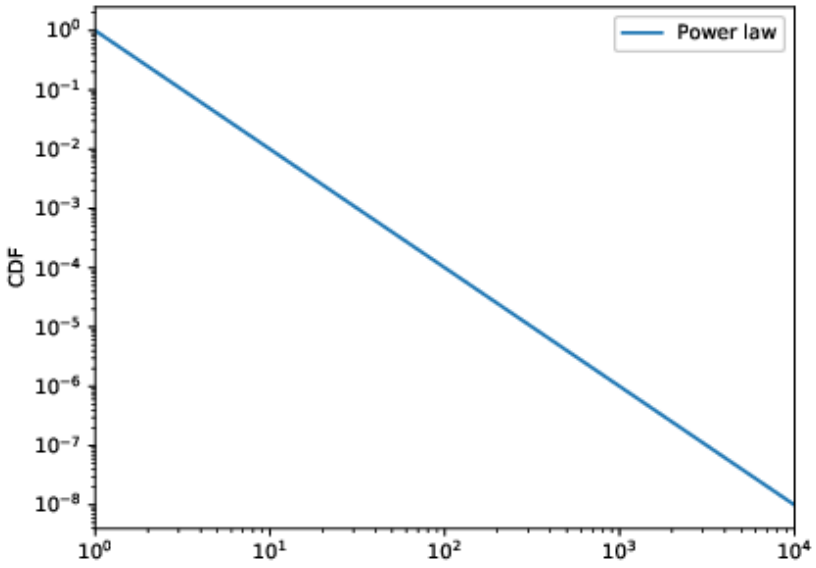
$$F(\geq x) = \int_x^{\infty} f(x)\, dx = \frac{x^{-\alpha}}{x_{min}^{-\alpha}}$$

- 累積分布関数(CDF)の指数部をべき指数と呼ぶが
  確率密度関数(PDF)表記$f(x) \propto x^{-(\alpha+1)}$の指数部を
  べき指数とする本や人も多いので注意
- 累積分布は$x \to \infty$で1になる定義と，$x \to \infty$で0になる定義
  2つ存在する（高安研では後者を採用）

モーメントが使えない確率分布

べき分布

- 下図はべき指数−2のべき分布($x \geq 1$)のCDF
- べき分布は両対数軸プロットで直線になる



べき分布に従う例

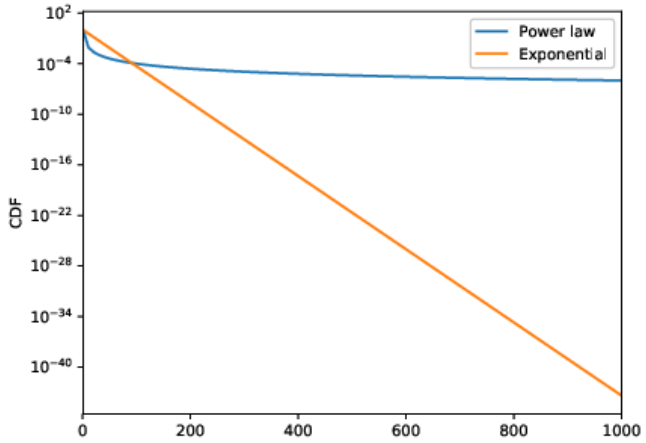
- 単語の出現頻度
- 生物の属の数と属が含む種の数の関係
- 株価の市場価格の差
- ガラスを割ったときの破片分布
- 地震の規模と頻度
- 都市の人口分布
- 人の移動距離分布など，，

べき分布の特徴

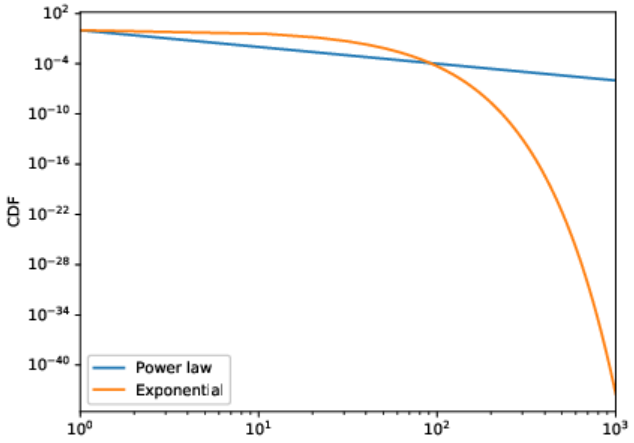
べき分布を説明する言葉として

ファットテール，裾野が広いなど

片対数グラフ



両対数グラフ



$\lambda = 0.1$の指数分布と，$\alpha = 0.5$のべき分布を比較$(x \geq 1)$

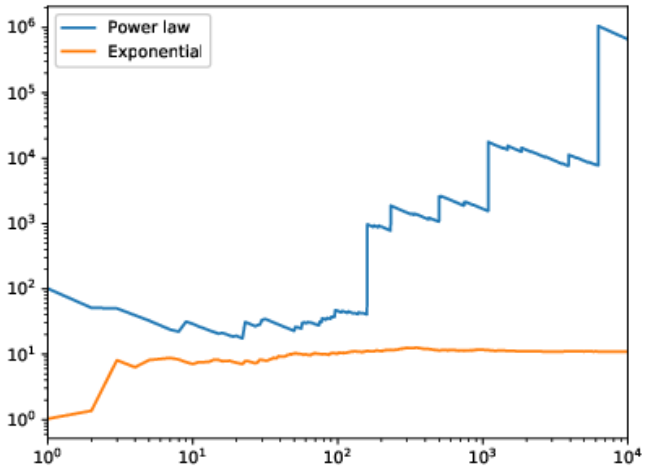
裾野が指数関数的に減少する指数分布や正規分布と比べて

べき分布はべき乗で緩やかに減少（極端に大きな値が現れる）

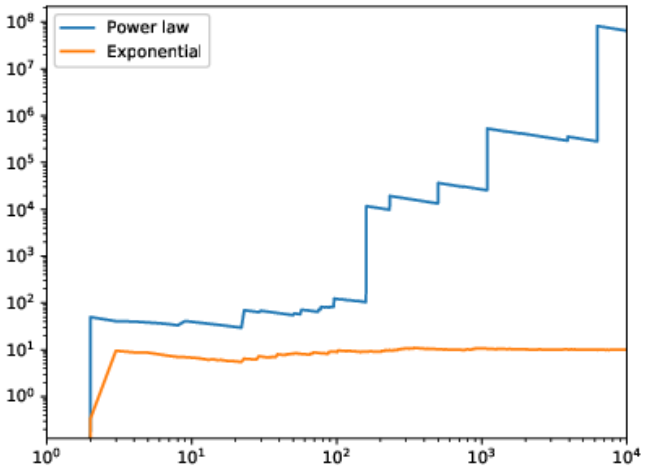
課題1：べき分布分布の平均・分散の発散

- $x \geq 1$においてべき分布($\alpha = 0.5$)・指数分布($\lambda = 0.1$)に従う乱数を各々10000個作る
- 1ステップごとに乱数を1つ増やし（10000個まで）その時点での平均・標準偏差を計算し比較
- 指数分布は平均値・標準偏差が収束するのに対しべき分布は発散する傾向があるのを確認

ステップ数-平均



ステップ数-標準偏差



べき分布の特徴（モーメントの発散）

n次の中心モーメント

$$\langle (x-\mu)^n \rangle \equiv \int_{-\infty}^{\infty} (x-\mu)^n f(x) dx$$

先ほどのべき指数0.5のべき分布の場合($f(x) \propto x^{-1.5}$)

平均の計算の時点で発散（$\mu \equiv \int_{-\infty}^{\infty} x f(x) dx$）

べき分布$F(\geq x) \propto x^{-\alpha}$において

- $0 < \alpha \leq 1$　　平均すら存在しない
- $1 < \alpha \leq 2$　　平均は存在する，分散は存在しない
- $2 < \alpha$　　αよりも小さい整数の次数のモーメントは存在する

べき分布の特徴（一般化中心極限定理）

べき分布（$\alpha \leq 2$）では中心極限定理が成り立たない

独立同分布に従う確率変数の組:$\{X_n\}_{1 \leq n}$

2次モーメントが有限 中心極限定理

母集団の期待値をμ, σ^2とする

$$\bar{X}_n \equiv \frac{\sum X_n - n\mu}{\sqrt{n}\sigma}$$

$\bar{X}_n$の分布は標準正規分布に漸近する

$$P(X_n \leq \alpha) \to \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\alpha} e^{-x^2/2} dx \ (n \to \infty)$$

2次のモーメントが発散した場合も含む 一般化中心極限定理

$$\bar{X}_n \equiv \frac{1}{n^{1/\alpha}} \sum (X_n - \mu)$$

nを無限大にしたとき

1つの分布に収束するならば$\bar{X}_n$は

安定分布と呼ばれる分布に収束する[1]

安定分布はべきの裾野を持つ

(安定分布に関しては次のページ)

[1] P. Levy and M. Borel, Gauthier-Villars, **Vol. 1**, (1954).

安定分布の特徴

安定分布

独立同一分布に従う確率変数（$X_1 \ldots X_n$）の和S_nとする

$S_n \overset{d}{=} C_n X + D_n$($d$は確率分布が同一を示す)を満たすとき

Xは安定な確率変数で，安定分布に従う

$$f(x) = \frac{1}{2\pi}\int_{-\infty}^{\infty} \varphi(t)\, e^{-ixt}\, dt$$

安定分布の確率密度関数は基本的に

解析的に書くことが出来ないため，特性関数で表記される

$$\varphi(t) = \begin{cases} \exp\left(-\gamma^{\alpha}|t|^{\alpha}\left[1 + i\beta\left(\left(\tan\frac{\pi\alpha}{2}\right)\mathrm{sign}(t)|\gamma t|^{1-\alpha} - 1\right)\right] + i\delta t\right) & \alpha \neq 1 \\ \exp\left(-\gamma|t|\left[1 + i\beta\frac{\pi}{2}\mathrm{sign}(t)\log(\gamma|t|)\right] + i\delta t\right) & \alpha = 1 \end{cases}$$

$$\mathrm{sign}(t)\begin{cases} -1 & t < 0 \\ 0 & t = 0 \\ 1 & t > 0 \end{cases}$$

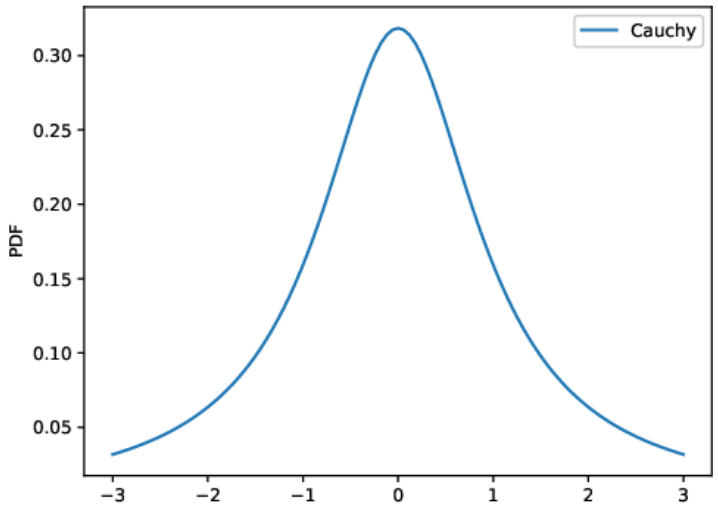
安定分布の特徴

安定分布

- 特性関数$\varphi(t)$は特性指数(α)
- 非対称パラメータ(β)
- 分布平行移動パラメータ(γ)
  変数の縮尺を変更するパラメータ(δ)で表される
- 最も重要なのは特性指数αで$|x| \to \infty$で漸近するべき分布のべき指数$(0 < \alpha \leq 2)$
- 非対称パラメータβは分布の対称性を表し$-1 \leq \beta \leq 1$をとる
- 正規分布も安定分布の一種であり（$\alpha = 2, \beta = 0$）例外的に
  べき乗の裾野を持たない安定分布の一種

安定分布で解析表現可能な確率分布例

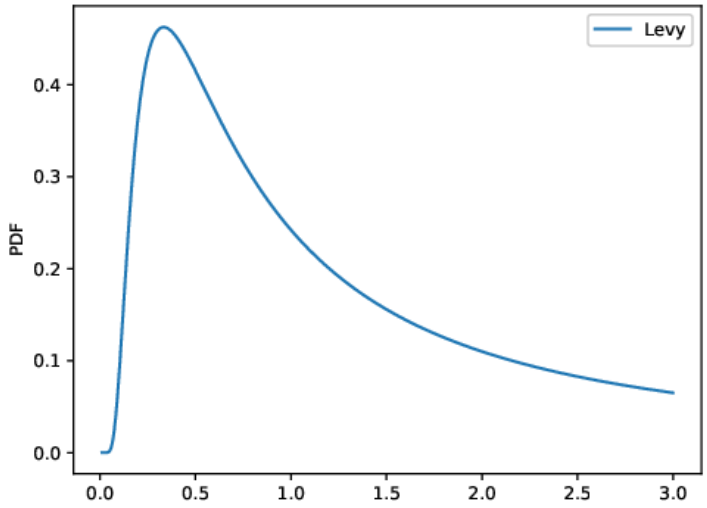
コーシー分布



$\alpha = 1, \beta = 0$の場合
コーシー分布

$f(x) = \frac{a}{\pi(x^2+a^2)}$に従う
描画例はa = 1

レヴィ分布



$\alpha = 0.5, \beta = 1$の場合
レヴィ分布

$f(x) = \sqrt{\frac{c}{2\pi}} \frac{e^{-\frac{c}{2x}}}{x^{\frac{3}{2}}}$に従う
描画例は$c = 1$

べき分布の特徴（一般化中心極限定理）

最近，安定分布の概念を更に拡張する研究も行われている[2]

- 安定分布の成り立つ条件「同じ分布に従う独立な確率変数の和」の「同じ分布」の条件を緩めるような研究

- ↑この論文言葉が先行し過ぎているのと，証明が怪しいらしく，何とも言えん
  まあ，調べれば批判記事出てくるのでどうぞ

[2] M. Shintani and K. Umeno, J. Phys. Soc. Japan **87**, 4 (2018).

べき分布に対する適切な要約統計量

べき分布の特徴量として
モーメントは不適であることが分かった
順序から導き出される別の要約統計量を導入

平均に代わる要約統計量

Tokyo Tech

中央値

- 標本を大きい順に並べたときの真ん中の値
- データ数によってはソート時間が面倒

最頻値

- ヒストグラムの最も度数が高い場所
- ヒストグラムの幅に依存

分散に代わる要約統計量

四分位範囲

- 標本を大きい順に並べたときの上位・下位25%
- データ数によってはソート時間が面倒

半値幅

- ヒストグラムの最も度数が高い場所から高さが半分になる場所
- ヒストグラムの幅に依存

最頻値・半値幅はヒストグラムの幅に依存して値が変わるため

中央値・四分位範囲を使う方が良い

課題2

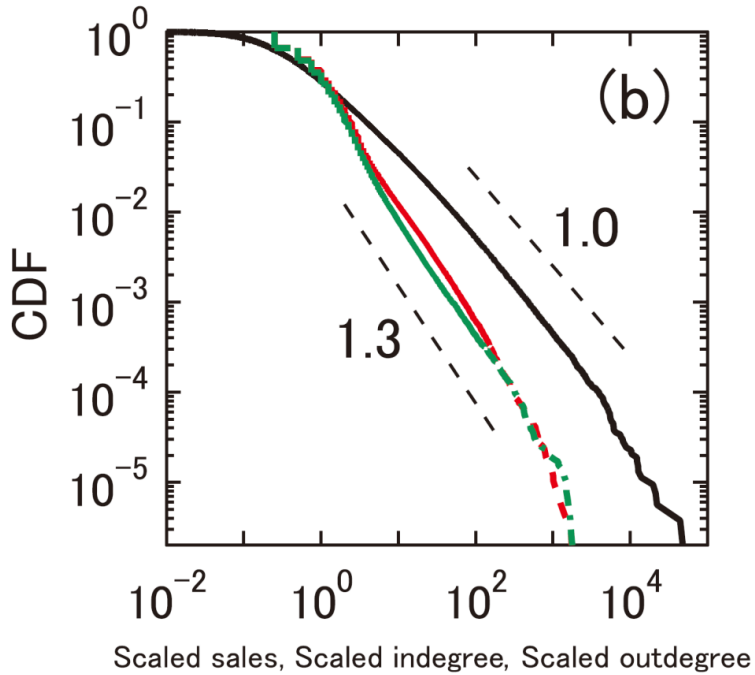
1. 適当なべき分布 $f(x) = Cx^{-(\alpha+1)}\ x \in [x_{min}, \infty)$ に従う乱数を発生させPDF,CDFを計算（PDFはBin幅に注意）
2. 中央値・四分位点を計算（奇数・偶数に注意）
3. 最尤法でべき指数を見積もり確認
4. 分布を綺麗に描画する

べき分布どこから線を引くか問題

べき分布がいつでもまっすぐだとは限らない

例えば下図[4]だと最初と最後が直線から外れている

曲線部を含めて最尤推定したらイカれることが予想される



[4] H. Watanabe, H. Takayasu, and M. Takayasu, New J. Phys. **14**, (2012).

べき分布どこから線を引くか問題

べき分布フィッティングにおけるパラメータはべき指数α，x_{min}

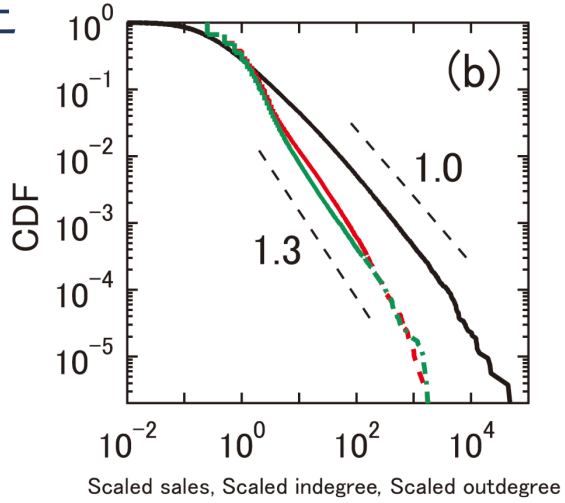
（x_{max}も考えても良いが，複雑になるしTruncatedも含めてホワイトボードで説明）

考えられるフィッテング方法として

①勘でそれっぽい線を引く

② $x_{min,max}$を勘で決めて，最尤法でαを推定

③ x_{min}もαもしっかり推定



[4] H. Watanabe, H. Takayasu, and M. Takayasu, New J. Phys. **14**, (2012).

べき分布どこから線を引くか問題

x_{min}, αをしっかり推定する方法を紹介する

Newman-Clausetのべき分布検定の前半部を使用[5]

[5] M. E. Clauset, Aaron and Shalizi, Cosma Rohilla and Newman, SIAM Rev. 51, 661 (2009).

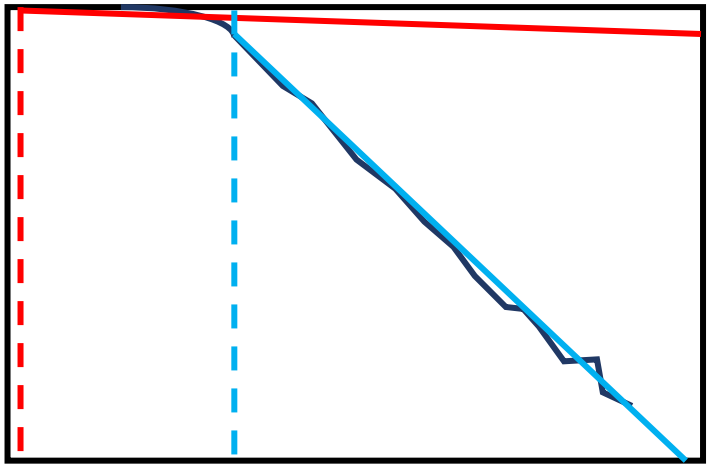
べき分布どこから線を引くか問題

右図のようなべき分布が得られたとする（赤点線がデータの最小値）

例えば全データ範囲でフィッテングすると

赤線のようなどうしようもないフィッテング線が引かれる

べき分布に従う最小値（水色点線）を見つけることが今回のゴール



べき分布どこから線を引くか問題

推定される確率密度関数は

$$f(x) = \frac{\alpha}{x_{min}^{-\alpha}} x^{-(\alpha+1)}, \qquad x \in [x_{min}, \infty)$$

データ数がn個だとすると対数尤度関数は

$$\log L(\alpha) = \mathrm{nlog}\,\alpha - \mathrm{nlog}\,x_{min} - (\alpha+1)\sum_{i}^{n} \log \frac{x_i}{x_{min}}$$

$\log L(\alpha)$を最大にするためのαは（αで微分して左辺に0を代入）

$$\alpha = n\left[\sum_{i}^{n} \log \frac{x_i}{x_{min}}\right]^{-1}$$

べき分布どこから線を引くか問題

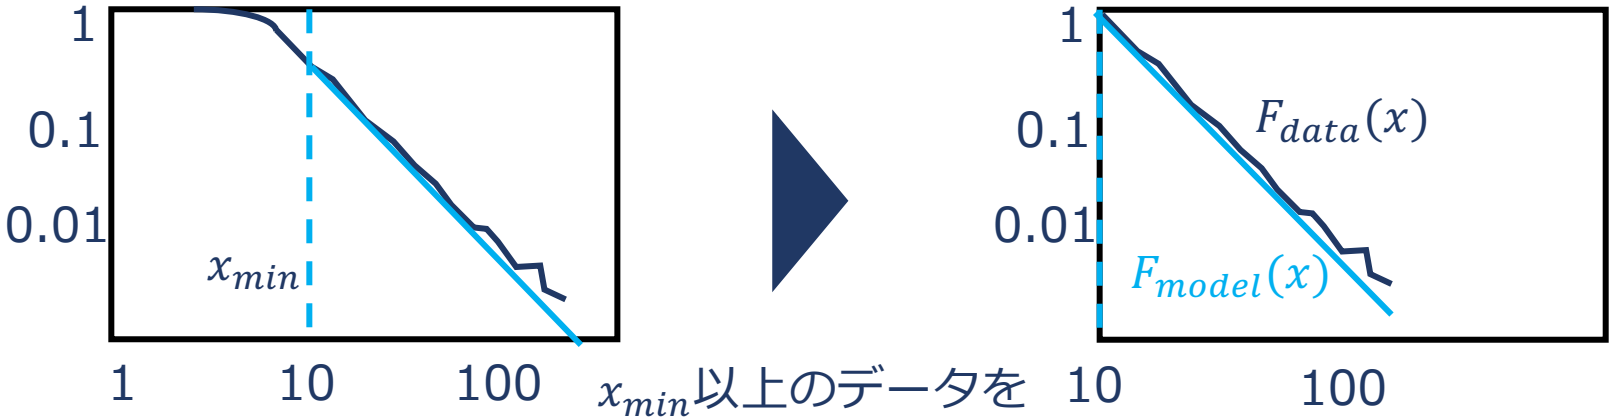
次にKS統計量$D_{x_{min}}$を以下と定義する

$$D_{x_{min}} = sup|F_{data}(x) - F_{model}(x)|$$

$F_{data}(x)$はデータの累積分布関数（右下図黒線）

$F_{model}(x)$は推定したαに従う累積分布関数（右下図水色線）

$F_{data}(x)$ と$F_{model}(x)$ の差が最も広くなるところが$D_{x_{min}}$



x_{min}以上のデータを抜き出して累積分布を再計算

べき分布どこから線を引くか問題

色々なx_{min}で計算を行い

最も$D_{x_{min}}$が小さくなるx_{min}が
最適なx_{min}として考えることが出来る

べき分布生成のメカニズム

これまでにべき分布の基本的な特性を学んだ

次にべき分布生成メカニズムを学ぶ

べき分布生成のメカニズム

べき分布生成メカニズムと現象への当てはめ

- 単語の出現頻度（指数分布と指数成長の組み合わせ）
- 生物の属の数と属が含む種の数の関係（Yule過程）

指数分布と指数成長の組み合わせ

指数分布に従う量yを考える

$$p(y) \sim e^{ay}$$

$x \sim e^{by}$の関係を満たすxの確率密度関数は

$$p(x) \sim p(y)\frac{dy}{dx} \sim \frac{e^{ay}}{be^{by}} = \frac{x^{-1+a/b}}{b}$$

指数分布に従う量があったとき，その量の指数関数で大きくなる変数はベキ分布に従う

上記の考え方を単語の出現頻度に適用[4]

[4]G. A. Miller, Am. J. Psychol. **70**, 311 (1957).

単語の出現頻度分布

アルファベットm文字の組み合わせで単語は構成され
空白で区別されるとする
まず，1つの文字または空白を選ぶとき
i番目の文字が選ばれる確率q_iは$q_i = \frac{1-q_s}{m}$で与えられる
（q_sは空白の確率）

次にy文字からなる単語を考える
y文字からなる単語のうち，ある特定の単語の出現頻度xは
$x = \left(\frac{1-q_s}{m}\right)^y$ $q_s \sim e^{by}$である

$$b = \ln(1-q_s) - \ln m$$

単語の出現頻度分布

y文字からなる単語のうち，特定の単語の出現頻度は分かった

次にy文字の単語が現れる確率を考える

長さy文字から$y+dy$文字にある単語の確率は

$p(y)\sim m^y = e^{ay}$と与えられる（$a = \ln m$）

以上より，先ほどの指数分布と指数成長の組み合わせによる

べき分布の導出法を適用すると，単語の出現分布が

べき分布に従うことが説明される

しかし，実際の文字はランダムではない

また，1文字を文字の1単位として良いのかという問題も(th)

シンプルな考え方だが，

実際の現象にそのまま適用するのは難しい

生物の属の数と属が含む種の数の関係

生物の属の数と属が含む種の数にはべき則の関係がある

属が含む種の数をk，kの種数を持つ属の数を$p(k)$とすると

$$p(k) \sim k^{-\rho}$$

となることが報告された（ρは定数）

この事実を説明する為に

1925年にYuleが提案した確率モデルがYule過程である[5]

[5] G. Udny Yule, Philos. Trans. R. Soc. London Ser. B **CCXIII**, 21 (1924).

Yule過程

種が絶滅しないとして考える

種は様々な要因で分裂し，また時折分裂した種は新たな属を作る

これが確率的に一定の割合で起こるとするとする

はじめに，以下のルールを設定する

- 1ステップごとに属の数が1つ増える
  この属には新しい1つの種が入る
- 分裂で起こる属内の種の数の増加は
  全体でm個とし，属内の種の数に比例して分配されるとする

Yule過程

パラメータを以下で設定

- n・・・属の数（1ステップで1つ増える）
- k_i・・・ i番目の属の数に入っている種の数
- m・・・1ステップで加わる種の数（k_iに応じて分配）
- p_k・・・k個の種を持つ属の数の分布

新たに加わる種はそれぞれの属が持つ種の数に応じて

優先的に分配される

1ステップで新たな属となる1つの種，分配されるm個の種

合計$m+1$種が1ステップごとに増える

Yule過程

nステップ目でk個の種を持つ属の数はnp_kで与えられる

新しく追加される種がi番目の属に分配される確率は

$$\frac{k_i}{\sum_{i'} k_{i'}} = \frac{k_i}{n(m+1)}$$

◀ nステップ目の種の総数

m個が分配されるので，1ステップの間でi番目の属に分配される個数は

$$m\frac{k_i}{\sum_{i'} k_{i'}} = \frac{mk_i}{n(m+1)}$$

- n・・・属の数（1ステップで1つ増える）
- k_i・・・ i番目の属の数に入っている種の数
- m・・・1ステップで加わる種の数（$k_{i,n}$に応じて分配）
- p_k・・・k個の種を持つ属の数の分布

Yule過程

サイズkの属が1ステップで獲得する新しい種の個数は

$$\frac{mk}{n(m+1)} \times np_k = \frac{mk}{(m+1)} p_k$$

- n・・・属の数（1ステップで1つ増える）
- k_i・・・ i番目の属の数に入っている種の数
- m・・・1ステップで加わる種の数（$k_{i,n}$に応じて分配）
- p_k・・・k個の種を持つ属の数の分布

Yule過程

基本的な量を与えたところで

$n+1$ステップ目にk個の種を獲得している属を考える

$n+1$ステップ目でk個の種を獲得している属はnステップ目を基準に

- nステップ目の時点でk個の種を持ち$n+1$ステップ目でも変わらない
- nステップ目の時点で$k-1$個の種を持ち$n+1$ステップ目でk個になる

$n+1$ステップ目でk個の種を持つ属の数は$(n+1)p_{k,n+1}$は
nステップ目の量を用いて以下のマスター方程式で与えられる

$$(n+1)p_{k,n+1} = np_{k,n} + \frac{m}{m+1}\left[(k-1)p_{k-1,n} - kp_{k,n}\right]$$

nステップ目の時点でk個の種を持ち$n+1$ステップ目で増える分を引く

Yule過程

1個の種しか持たない属は以下で与えられる

$$(n+1)p_{1,n+1} = np_{1,n} + 1 - \frac{m}{m+1}p_{1,n}$$

1ステップごとに属は必ず1つ増えるので

Yule過程

十分な時間が経ったとして$n \to \infty$とし，

$p_k = \lim_{n\to\infty} p_{k,n}$と表記する

$n \to \infty$における1種しか持たない属のp_1は

$$(n+1)p_{1,n+1} = np_{1,n} + 1 - \frac{m}{m+1}p_{1,n}$$

$\boldsymbol{n \to \infty}$

$$p_1 = 1 - \frac{m}{m+1}p_1$$

$$p_1 = \frac{m+1}{2m+1}$$

Yule過程

さらに$n+1$ステップ目でk個の種を持つ属の数$(n+1)p_{k,n+1}$に対しても同様に行うと

$$(n+1)p_{k,n+1} = np_{k,n} + \frac{m}{m+1}\left[(k-1)p_{k-1,n} - kp_{k,n}\right]$$

$\boldsymbol{n \to \infty}$

$$p_k = \frac{m}{m+1}\left[(k-1)p_{k-1} - kp_k\right]$$

$$p_k = \frac{k-1}{k+1+1/m}p_{k-1}$$

$$p_k = \frac{(k-1)(k-2)\ldots 1}{(k+1+1/m)(k+1/m)(3+1/m)}p_1$$

$$p_k = (1+1/m)\frac{(k-1)(k-2)\ldots 1}{(k+1+1/m)(k+1/m)(3+1/m)(2+1/m)}$$

Yule過程

$$p_k = (1+1/m)\frac{(k-1)(k-2)\ldots 1}{(k+1+1/m)(k+1/m)(3+1/m)(2+1/m)}$$

をΓ関数（$\Gamma(z+1) = z\Gamma(z)$）でまとめると

$$p_k = (1+1/m)\frac{\Gamma(k)\Gamma(2+1/m)}{\Gamma(k+2+1/m)}$$

さらにベータ関数（ex. $\mathrm{B}(x,y) = \frac{\Gamma(x)\Gamma(y)}{\Gamma(x+y)}$）でまとめると

$$p_k = (1+1/m)\mathrm{B}(k, 2+1/m)$$

Yule過程

$p_k = (1 + 1/m)\mathrm{B}(k, 2 + 1/m)$のベータ関数に注目する

ベータ関数$\mathrm{B}(x, y)$はxが大きい場所では（分布の裾）

$\mathrm{B}(x, y) \sim x^{-y}$のべき分布とほぼ等しい[6]

以上からkが大きい場所では

$$p_k \sim k^{-(2+1/m)}$$

とべき分布で近似できる

（べき指数$1 + \frac{1}{m}$のべき分布）

[6] S. C. Zanette, Damian H and Manrubia, Phys. A Stat. Mech. Its Appl. **295**, 1 (2001).

Yule過程

顕花（けんか）植物で観測されたべき則と
Yule過程から求められた理論値は非常によく一致している($m = 2$)

しかし，おそらくこの一致は偶然であると考えられている
種の絶滅などを無視しているため，現実に即していない可能性が高い

ただし，現代までにYule過程は様々な一般化がされており
都市のサイズ・論文の引用数・Webページのリンク関係など
いくつものアナロジーのモデルが提案されている

まとめ

べき分布の基本的な特性

- モーメントの発散
- 一般化中心極限定理
- 平均分散に代わる要約統計量
- べき分布検定

べき分布生成メカニズムと現象への当てはめ

- 単語の出現頻度（指数分布と指数成長の組み合わせ）
- 生物の属の数と属が含む種の数の関係（Yule過程）

その他参考文献

M. E. J. Newman, Contemp. Phys. 46, 323 (2005).
- べき分布についてうまくまとめられた論文

M. Takayasu and H. Takayasu, Encycl. Complex. Syst. Sci. 1 (2008).
- 経済現象でのべき分布レビュー

D. Sornette, Springer Sci. & Bus. Media (2006).
- 物理現象全般のべき分布や数理モデルに関して詳しく説明されている本