Programmingゼミ 第九回

時系列モデリング(ARモデル)；べき分布を導くモデル(1)

2023/06/21

Jiang, Jiwei

本日のゴール

- 1. 時系列モデル
  - ARモデル
    - シミュレーションで生成
    - パラメーターの推定
    - 予測、予測誤差
    - ARモデルの定常条件・単位根検定
  - 時系列モデリング
- 2. べき分布を導くモデル(1)
  - ランダム乗算過程モデル
  - シミュレーションで実装、べき指数を確認

時系列解析

- **時系列: 確率過程$\{X_t, t \in T\}$**
  - **時系列解析$\{x_t, t \in 1, 2, \ldots, n\}$**
    確率過程の一本の実現

線形モデル [編集] **https://ja.wikipedia.org/wiki/時系列**

時系列データのモデルには様々な形式がある。古典的に有名な線形モデルとしては、自己回帰移動平均モデル（ARMA）があり、これは自己回帰モデル（autoregressive; AR）と移動平均モデル（moving average; MA）を組み合わせたものである。更に、和分モデル（integrated; I）を組み合わせた自己回帰和分移動平均モデル（ARIMA）がある。これらは過去のデータ列およびノイズに線形に依存している。過去のデータへの非線形な依存は、カオス的時系列を生む可能性があり、興味深い。

状態空間モデル [編集]

「状態空間 (制御理論)」も参照

状態空間モデルとは、状態（観測不可能）を x_t、観測値（観測可能）を y_t、システムノイズ（状態遷移のノイズ）を v_t、観測ノイズを w_t として、以下で時系列 y_t を表現するモデル。[2][3]

$$x_t = f_t(x_{t-1}, v_t)$$
$$y_t = h_t(x_t, w_t)$$

このモデルは粒子フィルタ（モンテカルロ法）を用いて、状態 x_t の確率分布を求めることが出来る。関数 f_t と h_t には制限はないが、h_t は観測値から尤度（確率密度または確率質量）を逆算できることが必要。x_t や y_t は実数ベクトルである必要は無く、任意のデータ構造で良い。

状態および観測値が実数の列ベクトル、関数 f_t と h_t が線形（行列の乗法）、システムノイズ v_t と観測ノイズ w_t が多変量正規分布に従う場合は、以下のようになる。

$$x_t = F_t x_{t-1} + G_t v_t$$
$$y_t = H_t x_t + w_t$$

こちらは、状態 x_t の確率分布（多変量正規分布）をカルマンフィルターにて厳密解を求められる。ARMA や ARIMA もこの線形モデルで扱うことが出来る。

手法 [編集]

時系列データを分析するツールには以下のようなものがある:

- 自己相関関数とスペクトル密度関数
- 周波数領域の系列の分析としてのフーリエ変換
- ノイズを除去するデジタルフィルタの使用
- 主成分分析（または経験直交関数分析）
- 人工ニューラルネットワーク
- 時間-周波数解析手法:
  - 連続ウェーブレット変換
  - 短時間フーリエ変換
  - Chirplet変換
  - 非整数次フーリエ変換
- カオス解析
  - 相関次元
  - リカレンスプロット
  - 再帰定量化分析
  - リアプノフ指数
- 状態空間モデル
  - カルマンフィルター、拡張カルマンフィルタ、アンサンブルカルマンフィルタ
  - 粒子フィルタ

https://ja.wikipedia.org/wiki/時系列

- **参考教科書**
  - **北川源四郎**
    「時系列解析入門」岩波書店

スライド: http://www.mi.u-tokyo.ac.jp/mds-oudan/lecture_document_2019_math7/2018年度版/time_series_analysis.html

録画: https://ocwx.ocw.u-tokyo.ac.jp/course_11416/

復習：確率過程

確率過程：$\{X_t, t \in T\}$

- 平均, 分散
  - 定義: $\mu_t := EX_t, \sigma_t^2 := E(X_t - \mu_t)^2$
- 自己共分散
  - 定義: $\gamma(t,s) := E[(X_t - \mu_t)(X_s - \mu_s)], \sigma_t^2 = \gamma(t,t)$
- 自己相関
  - 定義: $\rho(t,s) := \frac{\gamma(t,s)}{\sqrt{Var(X_t)Var(X_s)}} = \frac{E[(X_t-\mu_t)(X_s-\mu_s)]}{\sqrt{Var(X_t)Var(X_s)}}$
- 定常性
  - 強定常：任意のt, τ, mに対して, $F(X_t, X_{t+1}, \dots, X_{t+m}) = F(X_{t+\tau}, X_{t+\tau+1}, \dots, X_{t+\tau+m})$
  - 弱定常：任意のt, τに対して,
    - 任意のtに対して, $EX_t^2 < \infty$
    - 任意のtに対して, $\mu_t = \mu$
    - 任意のt, τ, mに対して, $\gamma(t, t+\tau) = \gamma(k, k+\tau) = \gamma(\tau)$ $\sigma_t^2 = \gamma(0)$

    時間差のみに依存する

復習：確率過程

これからの解析対象

弱定常確率過程：$\{X_t, t \in T\} \rightarrow \{x_t, t = 1, 2, \dots, n\}$

- 平均:
  - 定義: $\mu_t = EX_t = \mu$
  - 推定: $\hat{u} = \bar{x} = \frac{\sum_{i=1}^{n} x_t}{n}$
- 自己共分散
  - 定義: $\gamma(k) := E[(X_t - \mu)(X_{t-k} - \mu)]$
  - 推定: $\hat{\gamma}(k) = \frac{\sum_{t=1}^{n-k}(x_t - \bar{x})(x_{t-k} - \bar{x})}{n-k}, 0 < k < n$

    $\hat{\gamma}(0) = \frac{\sum_{t=1}^{n}(x_t - \bar{x})^2}{n-1}$

    不偏推定
- 自己相関
  - 定義: $\rho(k) := \frac{\gamma(k)}{\gamma(0)}$
  - 推定: $\hat{\rho}(k) = \frac{\hat{\gamma}(k)}{\hat{\gamma}(0)}, 0 < k < n; \ \hat{\rho}(0) = \frac{\hat{\gamma}(0)}{\hat{\gamma}(0)} = 1$

自己回帰モデル（Autoregressive model, AR）

Auto and Regressive which represents the linear regression on itself (auto)

- $AR(p)$: $x_t = \phi_0 + \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \epsilon_t$
  - p: 自己回帰の次数
  - ϕ_1:自己回帰の係数
  - ϵ_t:ホワイトノイズ $\quad E[\varepsilon] = 0$

$$E[\varepsilon_k \varepsilon_l] = \begin{cases} \sigma^2 & k = l \\ 0 & k \neq l \end{cases}$$

- **ARモデルが定常になる条件**
  - 特性方程式：
    $\lambda^p - \phi_1 \lambda^{p-1} - \cdots - \phi_p \lambda = 0$
  - 定常に条件
    特徴方程式の根は全て単位円の内側になる，
    i.e. $|\lambda| < 1$

Eg: AR(1)

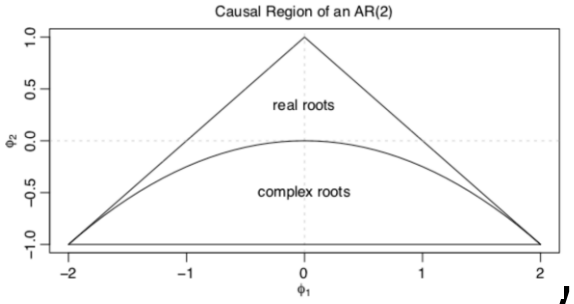
$\lambda - \phi_1 = 0$

$|\phi_1| < 1$の時、定常

Eg: AR(2)

$\lambda^2 - \phi_1 \lambda - \phi_2 = 0$

$$\begin{cases} |\phi_2| < 1 \\ \phi_2 \pm \phi_1 < 1 \end{cases}$$



定常条件の導出

- 中心化AR(p): $x_t = \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \epsilon_t$

→ $x_t - \phi_1 x_{t-1} - \cdots - \phi_p x_{t-p} = \epsilon_t \Leftrightarrow \Phi(B)x_t = \epsilon_t, \Phi(B) = (1 - \phi_1 B - \cdots - \phi_p B^p)$

非斉次線形差分方程式

一般解: $x_t = x_t' + x_t''$ （斉次の一般解＋非斉次の特解）

- **斉次の一般解：** $\lambda^p - \phi_1 \lambda^{p-1} - \cdots - \phi_p \lambda = 0$

  実数解：$\lambda_1 = \lambda_2 = \cdots = \lambda_d \in R$

  実数解：$\lambda_d \neq \lambda_{d+1} \neq \cdots \neq \lambda_{p-2m} \in R$

  共役複数解：$\lambda_{j1} = r_j e^{i\omega_j}, \lambda_{j2} = r_j e^{-i\omega_j}\ (j = 1, \ldots, m)$

  - $x_t' = \sum_{j=1}^{d} c_j\, t^{j-1} \lambda_1^t + \sum_{j=d+1}^{p-2m} c_j \lambda_j^t + \sum_{j=1}^{m} r_j^t \left(c_{1j} e^{it\omega_j} + c_{2j} e^{-it\omega_j}\right)$

- **非斉次特解:** $x_t'' = \frac{\epsilon_t}{\Phi(B)} = \frac{\epsilon_t}{\sum_{i=1}^{p}(1-\lambda_i B)} = \sum_{i=1}^{p} \frac{k_i}{1-\lambda_i B} \epsilon_t$

  - 特性方程式の解の逆数, $\{\frac{1}{\lambda_i}, i = 1, \ldots, p\}$, は$\Phi(B) = 0$の解 (証明簡単)

$$\therefore x_t = x_t' + x_t'' = \sum_{j=1}^{d} c_j\, t^{j-1} \lambda_1^t + \sum_{j=d+1}^{p-2m} c_j \lambda_j^t + \sum_{j=1}^{m} r_j^t \left(c_{1j} e^{it\omega_j} + c_{2j} e^{-it\omega_j}\right) + \sum_{i=1}^{p} \frac{k_i}{1 - \lambda_i B} \epsilon_t$$

- 定常条件： $\lim_{t\to\infty} x_t = 0 \Leftrightarrow \begin{cases} |\lambda_i| < 1, i = 1, 2, \ldots, p - 2m \\ |r_i| < 1, i = 1, 2, \ldots, m \end{cases}$

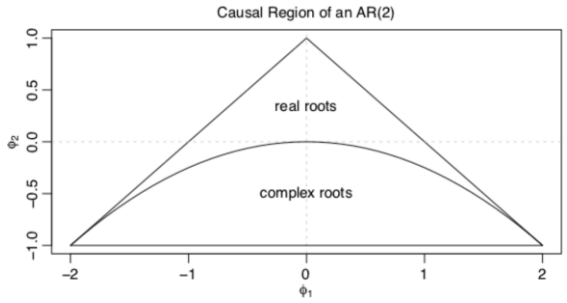
課題２ ARモデルを実装する

- 次のパラメータでARモデルを実装し、時系列をプロットする(以下全て$\sigma^2 = 1$)
  - $(1) M = 1, \phi_1 = 0.5$
  - $(2) M = 1, \phi_1 = -0.9$
  - $(3) M = 2, \phi_1 = 0.1, \phi_2 = 0.5$
  - $(4) M = 2, \phi_1 = 1.5, \phi_2 = -0.8$
- 以下の特徴量をチェックする
  - 平均
  - 自己相関
- 非定常になる場合のパラメータも試してみましょう

AR(2)定常条件

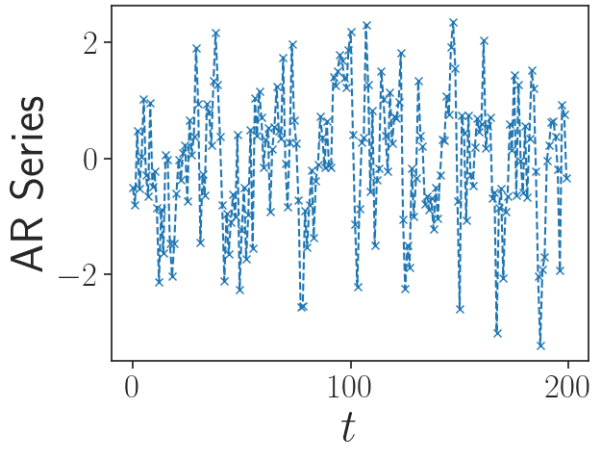
$$\lambda^2 - \phi_1 \lambda - \phi_2 = 0$$

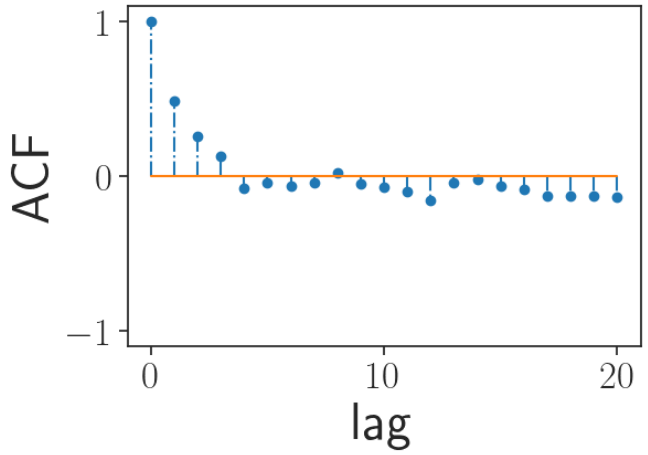
$$\begin{cases} |\phi_2| < 1 \\ \phi_2 \pm \phi_1 < 1 \end{cases}$$



答え

- $(1) M = 1, \phi_1 = 0.5$





(弱定常)ARモデルのパラメーター推定

- 与えられた時系列データに対応するARモデルを決める

AR(p): $x_t = \phi_0 + \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \epsilon_t$

パラメーター数: $(2 + p)$**個**

- 平均： $E[x_t] = E\left[\phi_0 + \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \epsilon_t\right]$
  - $\mu = E[x_t] = \frac{\phi_0}{1-\phi_1-\cdots-\phi_p}$, $\hat{u} = \overline{x} = \frac{\sum_{i=1}^{n} x_t}{n}$
- ホワイトノイズの分散
- AR係数：p個 (次数pはAICで決まる)
  - ユールウォーカー法
  - 最尤法
  - 最小二乗法

赤池情報量基準(AIC : Akaike Information Criterion)

モデル選択のための評価基準,
以下のAICを最小化するモデルを選択する

AIC = -2(最大対数尤度)+2(パラメータ数)

データへの当てはまりを良くしつつ、パラメータ数を抑制する

ユールウォーカー法

Yule-walker法, 実際は予測誤差分散の期待値を最小化と等価 (北川第六回P18)

- 中心化AR(p): $x_t = \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \epsilon_t$
  - 両辺にx_{t-k}を掛けて期待値を取る

$K = 0$: $E[x_t^2] = E\left[\phi_1 x_{t-1} x_t + \cdots + \phi_p x_{t-p} x_t + \epsilon_t x_t\right]$

$\rightarrow \gamma_0 = \sum_{i=1}^{p} \phi_i \gamma_i + \sigma^2$

$k = 1, \ldots, p$: $E[x_t x_{t-k}] = \mathrm{E}\left[\phi_1 x_{t-1} x_{t-k} + \cdots + \phi_p x_{t-p} x_{t-k} + \epsilon_t x_{t-k}\right]$

$\rightarrow \gamma_k = \sum_{i=1}^{p} \phi_i \gamma_{k-i}, k = 1, \ldots, p$

$$\begin{pmatrix} \gamma_1 \\ \vdots \\ \gamma_p \end{pmatrix} = \Gamma_p \begin{pmatrix} \phi_1 \\ \vdots \\ \phi_p \end{pmatrix} \qquad \Gamma_p := \begin{pmatrix} \gamma_0 & \gamma_1 & \cdots & \gamma_{p-1} \\ \gamma_1 & \gamma_0 & \cdots & \gamma_{p-2} \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_{p-1} & \gamma_{p-2} & \cdots & \gamma_0 \end{pmatrix}$$

Toeplitz 行列

Yule-walker 方程式

$$\gamma_0 = \sum_{i=1}^{p} \phi_i \gamma_i + \sigma^2 \quad (1)$$

$$\gamma_k = \sum_{i=1}^{p} \phi_i \gamma_{k-i} \ (k = 1, \ldots, p) \quad (2)$$

- 推定手順
  - 自己共分散γ_kをまで推定
  - (2)の線形連立方程式を解いて→$(\hat{\phi}_1, \ldots, \hat{\phi}_p)$
  - (1)より→$\widehat{\sigma^2} = \gamma_0 - \sum_{i=1}^{p} \hat{\phi}_i \gamma_i$
  - pはAICより決まる, AICを最小化するpを選択する

$AIC_p = N\left(log 2\pi\sigma_p^2 + 1\right) + 2(m+1)$

連立方程式を解く計算量が大きい

$O(p^3)$

更に, 次数を決めるためp回解く必要

$O(p^4)$

→計算効率が高い方法?

レビンソンのアルゴリズム (Levinson's Algorithm)

Theorem. AR(p) モデルに対応する Yule-walker 方程式は，ラグ $k = 0, 1, \cdots, p-1$ までの Yule-walker 方程式を逐次的に解いていくことで，帰納的に解ける．すなわち，AR(p) モデルのパラメータを $(\phi_1^{(p)}, \ldots, \phi_p^{(p)}, \sigma_p^2)$ と書くと，次の関係式が成り立つ．

1. ラグ $p = 0$ のとき，$\sigma_0^2 = \gamma_0$
2. ラグ $p \geq 1$ のとき，行列 Γ_{p-1} は正則で，AR($p-1$) モデルのパラメータ $(\phi_1^{(p-1)}, \ldots, \phi_{p-1}^{(p-1)}, \sigma_{p-1}^2)$ が推定されているとする．このとき，行列 Γ_p も正則で，AR(p) モデルのパラメータ $(\phi_1^{(p)}, \ldots, \phi_p^{(p)}, \sigma_p^2)$ は次のように求められる．

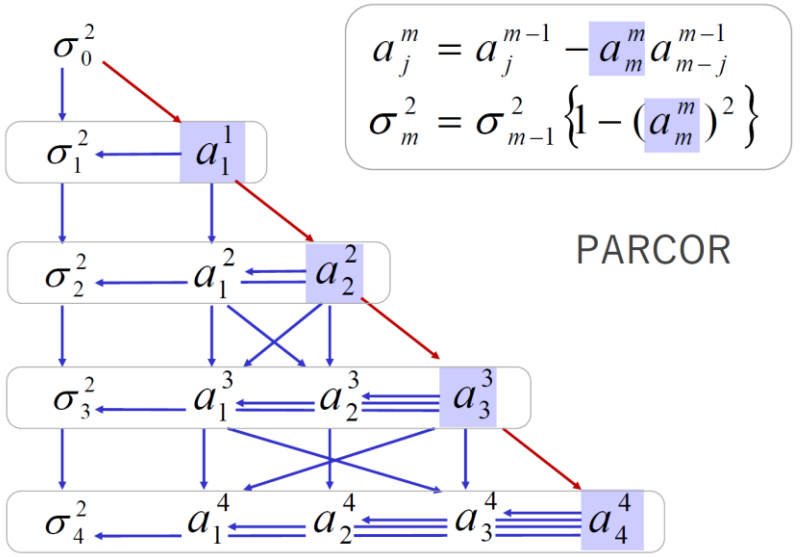
$$\phi_p^{(p)} = \left(\gamma_p - \sum_{i=1}^{p-1} \phi_i^{(p-1)} \gamma_{p-i} \right) \sigma_{p-1}^{-2} \tag{2.2.1}$$

$$\phi_k^{(p)} = \phi_k^{(p-1)} - \phi_{p-k}^{(p-1)} \phi_p^{(p)} \ (k = 1, \ldots, p-1) \tag{2.2.2}$$

$$\sigma_p^2 = \left(1 - (\phi_p^{(p)})^2 \right) \sigma_{p-1}^2 \tag{2.2.3}$$

$$AIC_p = N(\log 2\pi\sigma_p^2 + 1) + 2(m+1) \tag{2.2.4}$$

計算量: $O(p^2)$



偏自己相関係数PACF, Partial autocorrelation function

- **定義: (自己相関と区別)**
  - 定常時系列$\{x_t\}$において, $x_{t-1}, x_{t-2}, \dots, x_{t-k+1}$が指定された上の$x_t$と$x_k$の相関
  - $\rho_{x_t, x_{t-k} | x_{t-1}, x_{t-2}, \dots, x_{t-k+1}} := \frac{E[(x_t - \hat{E}x_t)(x_{t-k} - \hat{E}x_{t-k})]}{E[(x_{t-k} - \hat{E}x_{t-k})^2]}$

$$\hat{E}x_t = E[x_t | x_{t-1}, x_{t-2}, \dots, x_{t-k+1}]$$
$$\hat{E}x_{t-k} = E[x_{t-k} | x_{t-1}, x_{t-2}, \dots, x_{t-k+1}]$$

- $\rho_{x_t, x_{t-k} | x_{t-1}, x_{t-2}, \dots, x_{t-k+1}} \Leftrightarrow AR(k)$モデルの$k$次係数, ϕ_k

証明:

- $AR(k)$: $x_t = \phi_1 x_{t-1} + \cdots + \phi_p x_{t-k} + \epsilon_t$
- $\hat{E}x_t = E[x_t | x_{t-1}, x_{t-2}, \dots, x_{t-k+1}]$
  $= \phi_1 x_{t-1} + \phi_2 x_{t-2} \dots + \phi_{t-k+1} x_{t-k+1} + \hat{E}x_{t-k} + E[\epsilon_t | x_{t-1}, x_{t-2}, \dots, x_{t-k+1}]$
- $\therefore x_t - \hat{E}x_t = \phi_k (x_{t-k} - \hat{E}x_{t-k}) + \epsilon_t$
- $\therefore E[(x_t - \hat{E}x_t)(x_{t-k} - \hat{E}x_{t-k})] = \phi_k E\left[(x_{t-k} - \hat{E}x_{t-k})^2\right] + E[\epsilon_t (x_{t-k} - \hat{E}x_{t-k})]$
- $\therefore E[(x_t - \hat{E}x_t)(x_{t-k} - \hat{E}x_{t-k})] = \phi_k E\left[(x_{t-k} - \hat{E}x_{t-k})^2\right]$

$$\therefore \phi_k = \frac{E[(x_t - \hat{E}x_t)(x_{t-k} - \hat{E}x_{t-k})]}{E\left[(x_{t-k} - \hat{E}x_{t-k})^2\right]}$$

課題２ ARモデルのパラメーターを推定する

- 課題１で生成したAR時系列のパラメーターをユールウォーカー法で推定する
(できればレビンソンのアルゴリズムを使う)
  - $(1) M = 1, \phi_1 = 0.5$
  - $(2) M = 1, \phi_1 = -0.9$
  - $(3) M = 2, \phi_1 = 0.1, \phi_2 = 0.5$
  - $(4) M = 2, \phi_1 = 1.5, \phi_2 = -0.8$
- AICを次数20までプロット
- 偏自己相関関数をlag=20までプロット

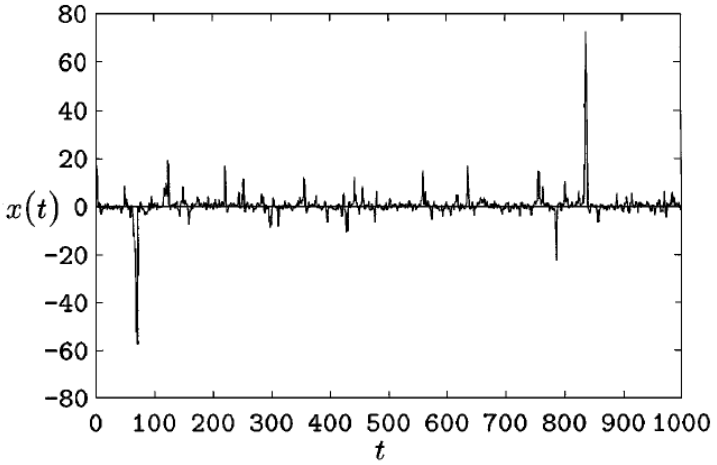
綺麗に描画できるplt関数
```
plt.stem(range(len(pacf)), pacf, linefmt="-.", markerfmt="o", basefmt="-")
```

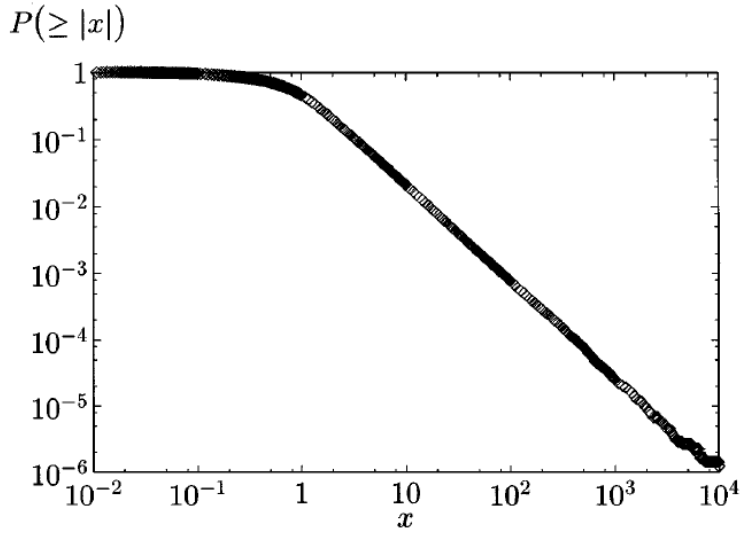
ランダム乗算過程

べき分布を導かれるシンプルなモデル

- $x(t+1) = b(t)x(t) + f(t)$
  - $b(t)$: $i.i.d, r.v.$ (乗算ノイズ)
  - $f(t)$: $i.i.d,$ (加算ノイズ)

AR(1)の拡張





一定値 $b(t) = b$ をとる場合

$$x(t+1) = b(t)x(t) + f(t)$$

- $b > 1$のとき
  指数関数にしたがって発散し,非定常となる.

- $b = 1$のとき
  ランダムウォークと一致. 非定常となる.

- $-1 < b < 1$のとき
  定常なAR(1)モデルと一致. 原点のまわりで定常的に揺らぐ.

$b(t)$がランダムに変動する場合

- 常に$|b(t)| < 1$のとき
  - X(t)は定常的な状態に収束する. 外力$f(t)$の分布の全てのモーメントが有限であれば, $x(t)$も全てのモーメントが有限な値をとる分布にしたがう.
- 有限の確率で増幅が起こる場合
  - $x(t)$の高次のモーメントが発散する.このとき,次式を満たすβが存在する. $\langle |b(t)|^{\alpha} \rangle = 1$
  - このとき,定常分布は次のようなべき分布となる.

$$P(\geq |x|) \propto |x|^{-\alpha}$$

ランダム乗算過程

- $x(t+1) = b(t)x(t) + f(t)$
  - $b(t)$: $i.i.d, r.v.$ (乗算ノイズ)
  - $f(t)$: $i.i.d,$ (加算ノイズ)

- 定常状態が存在するための条件

$$\langle \log b(t) \rangle < 0$$

- 定常分布のベキ指数

$$\langle |b(t)|^{\alpha} \rangle = 1,\ P(\geq |x|) \propto |x|^{-\alpha}$$

[1] Takayasu, H., Sato, A. H., & Takayasu, M. Physical Review Letters (1997).

課題3 ランダム乗算過程をシミュレーションする

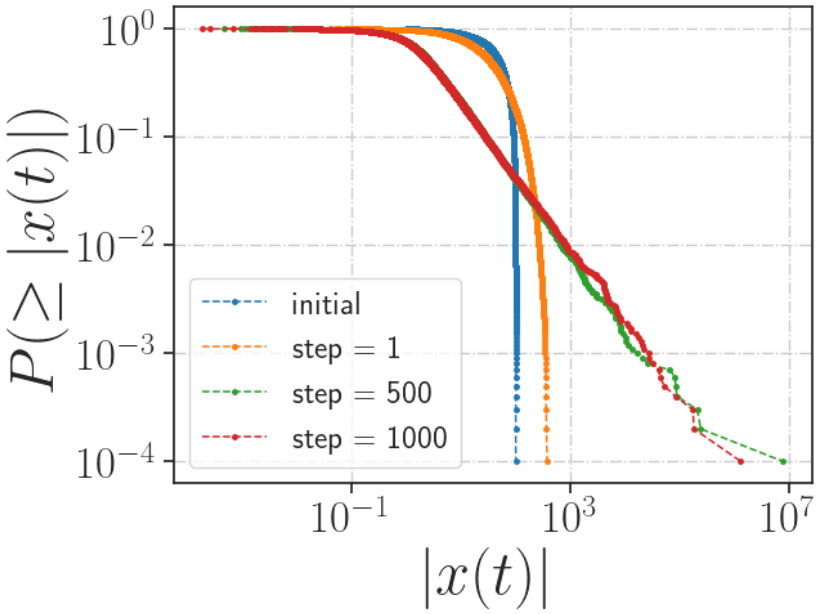
以下のパラメーターでシミュレーションしてみよう

- $x(t+1) = b(t)x(t) + f(t)$
  $f(t) \sim N(0,1), x(0) \sim U(1,100)$
  - $b(t) \sim U(0.1,\ 2.0)$
  - $b(t) \sim U(0.1,\ 2.5)$
- $|x|$の累積分布をチェックする
  - 定常？$\langle \log b(t) \rangle < 0$?
  - 定常であれば、べき指数をチェック
    - $\langle b^{\alpha} \rangle = 1 \rightarrow \alpha$ (bの乱数で数値的に計算する)

$$\langle \log b(t) \rangle = \frac{b \ln b - a \ln a - b + a}{b - a}$$

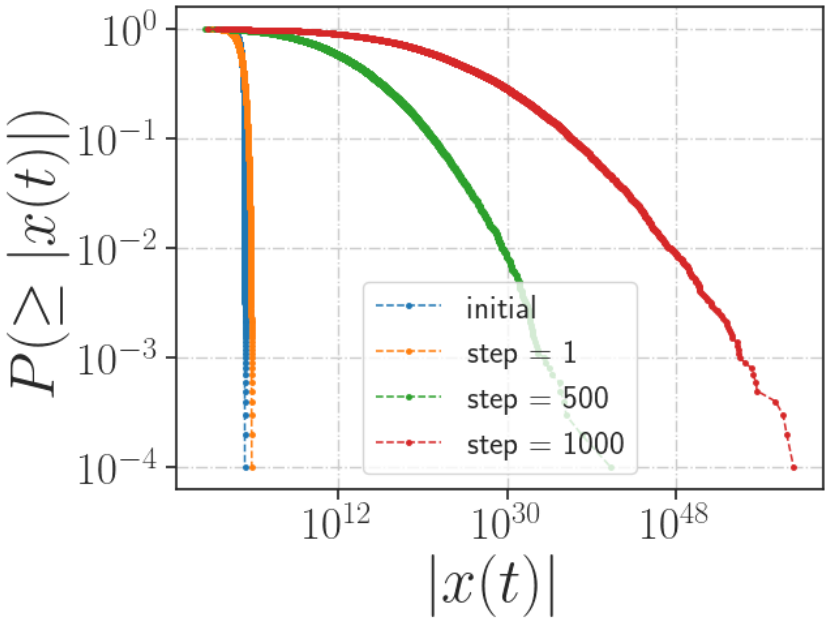
答え

$b(t) \sim U(0.1, 2.0)$



$\langle \log b(t) \rangle < 0$

$b(t) \sim U(0.1, 2.5)$



$\langle \log b(t) \rangle > 0$

$b(t) \sim U(0.1, 2.0)$, without noise

