木曜勉強会
自己回帰モデル (Autoregressive Model)

佐野　幸恵

2009 年 6 月 18 日

1　用語の説明

- 非定常 (nonstationary)
  時間的に平均値や分散などの統計量が変化すること。
  ランダムウォークで作った時系列 $X(t)$ が代表例。[Fig.1(a)]
  貨幣交換レートや、商品の毎月の売り上げの時系列のような経済データは、多くの場合非定常。

- 定常 (stationary)
  時間的に平均値や分散などの統計量が変化しないこと。
  ランダムウォークの差の時系列 $X(t+1) - X(t)$ が代表例。[Fig.1(b)]
  平衡状態にある物理系、生体等に多く見られる。

多くの時系列解析の理論や解析手法は、定常な確率過程に関して発展してきた。そのため、非定常時系列 $X(t)$ に何らかの変換を施し、定常な時系列 $Y(t)$ に直して、変換されたデータに関して時系列解析の手法を用いることが一般に行われている。主な変換のパターンをあげておく。なお、与えられた時系列に対してどのような変換を施すのが最もよいかといった問題は、時系列解析の中の重要な問題の一つ。

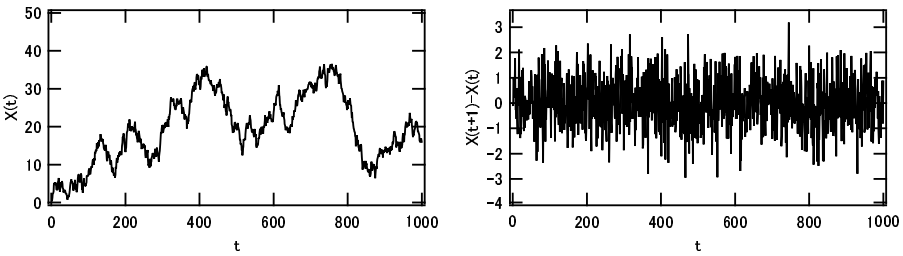


図 1: 平均 0、標準偏差 1 の正規乱数で作成したランダムウォークで作成した、(a) 非定常時系列 (左) と (b) 定常時系列 (右) の例

- 変数変換
  - 対数変換 $Y(t) = logX(t)$
  - ロジット変換　$Y(t) = log\left(\frac{X(t)}{1-X(t)}\right)$
    ある事象がおこる確率のような $(0,1)$ 上の値を取る時系列の場合に用いる。
- 差分（階差） $Y(t) = X(t+1) - X(t)$
- 比 $Y(t) = \frac{X(t+1)}{X(t})$
- 対数差分 $Y(t) = log\left(\frac{X(t+1)}{X(t)}\right)$

2　AR モデル (autoregressive model)

2.1　AR モデル

定常時系列モデルの一つで、日本語では自己回帰モデルとも言う。**定常**時系列 $Y(t)$ が与えられた時、

Autoregressive model

$$Y(t) = \sum_{i=1}^{M} a_i Y(t-i) + \varepsilon(t) \tag{1}$$

で表すことのできるモデルである。M は自己回帰の**次数**、a_i は**自己回帰係数**（重み）、$\varepsilon(t)$ は、平均 $\langle\varepsilon\rangle = 0$、標準偏差 σ^2 の正規分布に従う**白色雑音 (white noise)**（ノイズ成分）である。$\varepsilon(t)$ は、予測誤差という以上に、AR モデルを駆動する原動力としての役割を果たしているので、イノベーション (innovation=革新) と呼ぶこともある。パラメータとなるのは、次数 M と自己回帰係数 $a_1, \cdots, a_M$、および σ^2 であり、これらを推定する方法は後述する。

2.2　モデル式の説明

$Y(t)$ の予測値である

$$\hat{Y}(t) = \sum_{i=1}^{M} a_i Y(t-i) \tag{2}$$

は、M **次線形予測子 (linear predictor)** という。特に、**予測誤差 (prediction error) の 2 乗平均 (mean square)**、

$$\lim_{N\to\infty} \frac{1}{N} \sum_{t=1}^{N} \varepsilon^2(t) \tag{3}$$

が最小になるように自己回帰係数を選択した時の、M 次線形予測子を M **次最良線形予測子**という。

$\varepsilon(t)$ が M 次最良線形予測子の予測誤差であると、$\varepsilon(t)$ と、$Y(t-1), \cdots, Y(t-M)$ は無相関となる。

もし $\varepsilon(t)$ と $Y(t-M-1)$ との間に相関があれば、(2) 式の M を一つ大きくすることによって、(3) 式の予測誤差の 2 乗平均を小さくできるが、この操作を繰り返して、M が十分大きくなったところで、$\varepsilon(t)$ と $Y(t-1), Y(t-2), Y(t-3), \cdots$ の間に全く相関がなくなってしまうと、これ以上 (3) の値を改良することが不可能になる。この場合の予測子を"最良線形予測子"と呼び、予測誤差の時系列 $\varepsilon(t)$ は、白色雑音になっている。

自己回帰係数の和は、モデルの定常性と $\langle\varepsilon\rangle = 0$ より、

$$\sum_{j=1}^{M} a_j = 1 \tag{4}$$

が成り立つ。

2.3 モデルが定常である条件

どのような自己回帰係数 a_i を持ってきても、(1) 式で生成されるモデルが定常になるわけではない。以下に示す z に関する M 次方程式（**AR モデルの特性方程式**）、

$$1 - a_1 z - a_2 z^2 - \cdots - a_M z^M = 0 \tag{5}$$

の M 個の根（**特性根**）の絶対値がすべて 1 より小さいことが必要である。特性根の位置に関するこの条件は、$\varepsilon(t)$ がすべて 0 であれば、どんな初期値から出発しても、$x(t)$ が $t \to \infty$ の極限で 0 に収束することを保証する。

具体的に確認しておく。(1) 式を $M = 1$ の場合で具体的に書き下していくと、

$$\begin{aligned} Y(t) &= a_1 Y(t-1) + \varepsilon(t) \\ &= a_1 \left(a_1 Y(t-2) + \varepsilon(t-1)\right) + \varepsilon(t) \end{aligned}$$

n までさかのぼるとして、

$$= a_1^n x(t-n) + \sum_{j=0}^{n-1} a_i^j \varepsilon(t-j) \tag{6}$$

ここで定常性を確認するため、$Y(t)$ の t についての時間平均 $E[Y(t)]$ を考える。すなわち、$E[Y(t)]$ の値が t に依存しなければ、定常性が保証されることになる。

$$E[Y(t)] = a_1^n E[Y(t-n)] + \sum_{j=0}^{n-1} a_1^j E[\varepsilon(t-j)] \tag{7}$$

1. $|a_i| \geq 1$ のとき $n \to \infty$ で、(7) 式の右辺の第 1 項は収束せず、観測時間に応じて平均値が異なるため非定常となる。

2. $|a_i| < 1$ のとき $n \to \infty$ で、(7) 式の右辺の第 1 項は 0 に収束し、第 2 項のみが残る。

$$Y(t) = \sum_{j=0}^{\infty} a_1^j \varepsilon(t-j) \tag{8}$$

ここで、t についての二乗平均（分散）を取ると、

$$\begin{aligned} E\left[Y(t)^2\right] &= \sum_{j=0}^{\infty} a_1^{2j} E\left[\varepsilon(t-j)^2\right] \\ &= \sigma^2 \sum_{j=0}^{\infty} a_1^{2j} = \frac{\sigma^2}{1-a_1^2} = const. \end{aligned} \tag{9}$$

すなわち、$|a| < 1$ なら $Y(t)$ の統計量である分散が時間に応じて変化しないため、定常と言える。

特性根に関する条件が満たされている時の (1) 式を、**AR モデル**という。

3 ユール・ウォーカー (Yule-Walker) 方程式

ユール・ウォーカー方程式とは、自己回帰係数 a_i と自己共分散関数 C_k の関係式である。

Yule-Walker Equation

$$\begin{aligned} C_0 &= \sum_{j=1}^{M} a_j C_j + \sigma^2 \\ C_k &= \sum_{j=1}^{M} a_i C_{k-j} \end{aligned} \tag{10}$$

(1) 式の両辺に $\varepsilon(t)$ をかけて平均を取る。$Y(t-j)$ と $\varepsilon(t)$ は無相関なので、

$$E\left[\varepsilon(t)Y(t)\right] = E\left[\varepsilon(t)^2\right] = \sigma^2 \tag{11}$$

(1) 式の両辺に $Y(t)$ をかけて平均を取る。

$$E\left[Y(t)^2\right] = \sum_{j=1}^{M} a_j E\left[Y(t)Y(t-j)\right] + \sigma^2 \tag{12}$$

(1) 式の両辺に $Y(t-k)$ をかけて平均を取る。

$$E\left[Y(t-k)Y(t)\right] = \sum_{j=1}^{M} a_j E\left[Y(t-k)Y(t-j)\right] (k = 1, 2, \cdots) \tag{13}$$

自己共分散関数 $C_{k=0}$ は、(11) より、

$$C_0 = E\left[Y(t)^2\right] = \sum_{j=1}^{M} a_j E\left[Y(t)Y(t-j)\right] + \sigma^2 \tag{14}$$

自己共分散関数 $C_{k\neq 0}$ は、(12) より、

$$C_k = E\left[Y(t-k)Y(t)\right] = \sum_{j=1}^{M} a_j C(k-j) \tag{15}$$

ここで、定常過程を仮定しているので、$C_{k-j} = C_{j-k}$ を用いた。
さらに (14) 式を行列式で書き下しておくと、

$$\begin{pmatrix} C_0 & C_1 & \dots & C_{M-1} \\ C_1 & C_0 & \dots & C_{M-2} \\ \vdots & \vdots & \ddots & \vdots \\ C_{M-1} & C_{M-2} & \dots & C_0 \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_M \end{pmatrix} = \begin{pmatrix} C_1 \\ C_2 \\ \vdots \\ C_M \end{pmatrix} \tag{16}$$

となる。さらに、(13) 式より、σ^2 が求めることができる。
ユール・ウォーカー方程式でうれしいことは、自己共分散 C_k が分かると、AR モデルの自己回帰係数 a_i と σ^2 が分かる、ということである。
AR モデルの予測誤差の分散値 $E\left[\varepsilon(t)^2\right]$ が最小値を取る場合の、自己共分散関数が満たす関係式を確認しておく。

$$\begin{aligned} E\left[\varepsilon(t)^2\right] &= E\left[\left(Y(t) - \sum_{j=1}^{M} a_j Y(t-j)\right)^2\right] \\ &= C_0 - 2\sum_{j=1}^{M} a_j C_j + \sum_{j=1}^{M}\sum_{i=1}^{M} a_j a_i C_{j-i} \end{aligned} \tag{17}$$

となり、二乗した値が最小になる場合、

$$\frac{\partial E\left(\varepsilon^2\right)}{\partial a_i} = -2C_i + 2\sum_{i=1}^{M} a_i C_{j-i} = 0 \tag{18}$$

となり、(15) と等価である。

4 レビンソンのアルゴリズム (Levinson algorithm)

前のセクションでユール・ウォーカー方程式を利用し、与えられた時系列 $Y(t)$ から、自己共分散 C_i を求め、n 元 1 次方程式を解くことで、AR モデルの自己回帰係数 a_i を求めることができることが分かった。
しかし、M の値が大きくなると計算量が多くなり、実装には不向きである。ここ

で、対称性をうまく利用したレビンソンのアルゴリズム (Levinson algorithm)、(または、レビンソン・ダービンのアルゴリズム (Levinson-Durbin algorithm) とも言う) を使うことで、代入計算の繰り返しで逐次的に解け、計算量が軽減されるため、計算機に実装する場合、こちらの方法がよく使われる。
アルゴリズム中で、最良な M の値も同時に求めることができるが、その際に、用いられる AIC(Akaike Information Criterion) について説明しておく。AIC は「情報量規準」の一つで 1971 年に元統計数理研究所所長のの赤池弘次が考案した。統計モデルの良さを評価するための指標で、AIC は「モデルの複雑さと、データの適合度とのバランスを取る」ために使用される。具体的には以下の式で表わされ、AIC の値が最小になる M の値を選択すればよい。

$$AIC = -2logL + 2k \tag{19}$$

L は最大尤度、k は自由パラメータの数。なお、情報量基準には他にも BIC(Bayesian Information Criterion) や GIC(Generalized Information Criterion) などがあり、それだけで本が一冊あるくらいなので、ここでは深入りしない。

レビンソンのアルゴリズムの方針としては、$m = 0$ の場合の AIC_0 と σ_0^2 からスタートし、1 次の AR モデル式、$m = 1$ の場合の a_1^1 と AIC_1 と σ_1^2、$m = 2$ の場合の a_1^2, a_2^2 と AIC_2 と σ_2^2、と順に求めて、AIC_m が最小になるところで最良の $M = m$ を決定するという流れになっている。予め計算して準備しておくのは、与えられた時系列の自己共分散関数 $C_0, C_1, \cdots, C_M$ である。

Levinson algorithm

$m = 0$ のとき

$$\sigma_0^2 = C_0 \tag{20}$$

$$AIC_0 = N\left(log2\pi\sigma_0^2 + 1\right) + 2 \tag{21}$$

$m = 1, 2, \cdots$,M のとき

$$a_m^m = \left(C_m - \sum_{j=1}^{m-1} a_j^{m-1} C_{m-j}\right)\left(\sigma_{m-1}^2\right)^{-1} \tag{22}$$

$$a_i^m = a_i^{m-1} - a_m^m a_{m-i}^{m-1} \tag{23}$$

$$\sigma_m^2 = \sigma_{m-1}^2\{1 - (a_m^m)^2\} \tag{24}$$

$$AIC_m = N\left(log2\pi\sigma_m^2 + 1\right) + 2(m+1) \tag{25}$$

AIC が、定義式とやや異なるのは、誤差の分布に正規分布を仮定して計算していることに由来する。

5 appendix

♡ 自己共分散関数について

共分散 (covariance) → 2 変数の相関を見る尺度。共分散をそれぞれの標準偏差の積で割った値が、**相関係数 (correlation coefficient)**。

自己共分散 (autocovariance) → 自分自身の時間を k ずらしたところとの相関をみる尺度。自己共分散を分散で割った値が、**自己相関関数 (autocorrelation function)**。

どちらの概念も、対象とする変数の**定常性**を仮定していることに注意が必要である。

時系列 $Y(t)$ が与えられた時の自己共分散関数 C_k を定義しておく。

Autocovariance

$$C_k = E[Y(t)Y(t+k)] - E[Y]^2 \tag{26}$$

定義から式 (26) の導出方法を確認しておく。

$$C_k = E[(Y(t) - E[Y(t)])\,(Y(t+k) - E[Y(t+k)])]$$

$Y(t)$ の定常性を仮定しているので、$E[Y(t)] = E[Y(t+k)] = E[Y]$

$$\begin{aligned} &= E[Y(t)Y(t+k)] - E[Y]E[Y(t)] - E[Y]E[Y(t+k)] + E[Y]^2 \\ &= E[Y(t)Y(t+k)] - E[Y]E[Y] - E[Y]E[Y] + E[Y]^2 \\ &= E[Y(t)Y(t+k)] - E[Y]^2 \end{aligned} \tag{27}$$

しかし、これは無限長のデータがある場合の理論値であり、実際はデータは有限個であり、特に平均値 $E[Y]$ を出す時のサンプル数をどうするか、などが問題になる。データが有限個の場合はどの区間 k でもサンプルが同じになるように計算する。

$$C_k = \frac{1}{n-k}\sum_{t=1}^{n-k} Y(t)Y(t+k) - \frac{1}{(n-k)^2}\left(\sum_{t=1}^{n-k} Y(t)\right)\left(\sum_{t=1}^{n-k} Y(t+k)\right) \tag{28}$$

k が大きい時にはサンプルが少なくなるが、どんな k の場合でも $n-k$ の値が同じになるよう計算する必要がある。特に $t+k$ の値が与えられた時系列の最大数 t_{Max} を超えないように注意する。

参考文献

[1] 北川源四郎 「時系列解析入門」 (岩波書店,2005)

[2] 尾崎統、北川源四郎　「統計科学選書 5 時系列解析の方法」　(朝倉書店,1998)

[3] 小西貞則、北川源四郎　「シリーズ予測と発見の科学 2 情報量基準」(朝倉書店,2004)

[4] 蓑谷千凰彦　「統計学入門」　(東京図書,1994)

[5] Takayuki Mizuno, Hideki Takayasu, and Misako Takayasu, "Analysis of price diffusion in financial markets using PUCK model", PhysicaA **382** (2007) 187-192 （定常性の判定についての記載もあり。）