AR モデル

長山

2023 年 6 月 5 日

時系列解析を AR モデルで推定するときに必要となる知識を基本的なところからまとめる．

1　時系列

時系列とは，時間で添字づけられた観測値 x_t の羅列 $\{x_t \,|\, t = 1, \ldots, T\}$ のことである．主に確率過程として定式化される．

1.1　統計量

理論的に母平均，母分散，母自己共分散を定義．1 本の時系列から推定する方法も書く．

1.2　定常性

時系列の変化を追いかける際，平均値のシフトや揺らぎの拡大など，各時刻で取りうる値の性質が大きく変化する場合，過去の値から未来の値のふるまいを推測することが困難となる．そこで，時系列データをモデル化する際には，データの性質が時間によらず一定であるという**定常性 (stationarity)** を仮定することが多い．定常性には次の 2 つの定義がある．

Definition. 時系列が次の条件を満たすとき，**強定常 (strict/strong stationary)** であるという．

1. 任意の時刻で，任意のラグまでの連続時間同時分布が一定．

$$^{\forall}t, \, ^{\forall}k \,;\; F(x_t, \ldots, x_{t-k}) = F(x_k, \ldots, x_0) \tag{1.2.1}$$

強定常性ではモーメントの有限性は仮定しない．各時刻が独立同分布に従う時系列 (iid 時系列) は強定常である．非自明な（独立でない）例が見つからない．実データでは確かめようがない．

Definition. 時系列が次の 3 つの条件を満たすとき，**弱定常 (weakly stationary)** であるという．共分散定常ともいう．

1. 任意の時刻で平均が有限かつ一定．

$$^{\forall}t;\ E[x_t] = \mu\ < \infty \tag{1.2.2}$$

2. 任意の時刻で 2 次モーメントが有限．

$$^{\forall}t;\ E[x_t^2] < \infty \tag{1.2.3}$$

3. 任意の時刻で，任意のラグに対する自己共分散が一定．

$$^{\forall}t,\ ^{\forall}k;\ Cov(x_t, x_{t-k}) = \gamma_k \tag{1.2.4}$$

条件 1,2 のもと，分散と自己共分散が有限であることは簡単に確かめられる．分散の有限性は

$$\gamma_0 = Var(x_t) = E[x_t^2] - \mu^2 < \infty \tag{1.2.5}$$

のように示せる．ラグ $k \geq 1$ に対する自己共分散の有限性は，恒等式

$$E[x_t^2] + E[x_{t-k}^2] - 2E[x_t x_{t-k}] = E[(x_t - x_{t-k})^2] \geq 0 \tag{1.2.6}$$

を利用すると，

$$\gamma_k = Cov(x_t, x_{t-k}) = E[x_t x_{t-k}] - \mu^2 \leq \frac{E[x_t^2] + E[x_{t-k}^2]}{2} - \mu^2 < \infty \tag{1.2.7}$$

のように示せる．従って，最初から自己共分散の有限性を定義に含めてしまっても問題ない．
弱定常な時系列の代表例が次に示す**ホワイトノイズ**である．

Definition. 次の 3 つの条件を満たす時系列を**ホワイトノイズ (white noise)** という．特に，分散が σ^2 のホワイトノイズを $W.N.(\sigma^2)$ などと書く．

1. 任意の時刻で平均が 0.

$$^{\forall}t;\ E[x_t] = 0 \tag{1.2.8}$$

2. 任意の時刻で分散が有限かつ一定．

$$^{\forall}t;\ Var(x_t) = \sigma^2 < \infty \tag{1.2.9}$$

3. 異時刻相関がない．

$$^{\forall}t, s\ (t \neq s);\ Cov(x_t, x_s) = 0 \tag{1.2.10}$$

ホワイトノイズの典型例が正規分布 $N(0, \sigma^2)$ の iid 時系列である．
独立性も同分布性も仮定していない．独立だが同分布でないホワイトノイズは簡単に作れる．平均と分散が同じ複数の分布を用意して時刻ごとに異なる分布から値を生成すれば良い．例えば次の 3 つの分布はすべて平均 0，分散 1 である．

- 標準正規分布 $N(0,1)$
- 一様分布 $U(-\sqrt{3},\sqrt{3})$
- 非対称な 2 値分布 $\Pr(x)=\begin{cases}\frac{2}{3}\ , & x=\frac{1}{\sqrt{6}}\\ \frac{1}{3}\ , & x=-\frac{2}{\sqrt{6}}\end{cases}$

2 AR モデル

AR(p) モデルとは，直前の p 個の履歴を用いて次の値を説明する線形モデルである．

$$\begin{aligned} x_t &= \sum_{i=1}^{p} a_i x_{t-i} + \varepsilon_t \\ \varepsilon_t &\sim W.N.(\sigma^2) \end{aligned} \tag{2.0.1}$$

誤差項はホワイトノイズであれば良く，同分布性は仮定しない[*1]．

2.1 Yule-walker 方程式

ここからは，平均が 0 となるようにシフトした弱定常時系列を考える．

Theorem. 弱定常な AR(p) 過程に従う時系列の自己共分散は次の関係を満たす．

$$\begin{aligned} \gamma_0 &= \sum_{i=1}^{p} a_i \gamma_i + \sigma^2 \\ \gamma_k &= \sum_{i=1}^{p} a_i \gamma_{k-i} \ (k=1,\dots,p) \end{aligned} \tag{2.1.1}$$

この連立 $p+1$ 次方程式を **Yule-walker 方程式**という．2 つ目の条件を行列表記すると次のようになる．

$$\begin{pmatrix} \gamma_1 \\ \vdots \\ \gamma_p \end{pmatrix} = \Gamma_p \begin{pmatrix} a_1 \\ \vdots \\ a_p \end{pmatrix} \tag{2.1.2}$$

where

$$\Gamma_p := \begin{pmatrix} \gamma_0 & \gamma_1 & \cdots & \gamma_{p-1} \\ \gamma_1 & \gamma_0 & \cdots & \gamma_{p-2} \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_{p-1} & \gamma_{p-2} & \cdots & \gamma_0 \end{pmatrix} \tag{2.1.3}$$

行列 Γ_p は対称な Toeplitz 行列であり，対角要素が定数となる．

[*1] AR モデルの推定で同分布性を仮定しているか確認する．

Proof. t を任意の時刻とする，AR(p) モデルにおいて，両辺に x_t を掛けて期待値を取ると

$$\begin{aligned} x_t^2 &= \sum_{i=1}^{p} a_i x_{t_i} x_t + \varepsilon_t x_t \\ E[x_t^2] &= \sum_{i=1}^{p} a_i E[x_{t_i} x_t] + E[\varepsilon_t x_t] \\ \gamma_0 &= \sum_{i=1}^{p} a_i \gamma_i + \sigma^2 \end{aligned} \tag{2.1.4}$$

を得る．ここで，2 つ目の等式から 3 つ目の等式への変換に弱定常性と ε_t が $W.N.(\sigma^2)$ であることを用いた．同様に，ラグ $k = 1, \ldots, p$ について，両辺に x_{t-k} を掛けて期待値を取ると

$$\begin{aligned} x_t x_{t-k} &= \sum_{i=1}^{p} a_i x_{t_i} x_{t-k-i} + \varepsilon_t x_{t-k} \\ E[x_t x_{t-k}] &= \sum_{i=1}^{p} a_i E[x_{t_i} x_{t-k}] + E[\varepsilon_t x_{t-k}] \\ \gamma_k &= \sum_{i=1}^{p} a_i \gamma_{k-i} \end{aligned} \tag{2.1.5}$$

を得る．

2.2 Levinson のアルゴリズム

ラグ p までの自己共分散が求めっているとき，Yule-walker 方程式を解くことで AR(p) モデルの $p+1$ 個のパラメータ $(a_1, \ldots, a_p, \sigma^2)$ を推定できる．Naive には p 次正方行列の逆行列を解けるが，対称 Toeplitz 行列の性質を使うと $O(p)$ の計算量で解を求めることができる．

Theorem. AR(p) モデルに対応する Yule-walker 方程式は，ラグ $k = 0, 1, \cdots, p-1$ までの Yule-walker 方程式を逐次的に解いていくことで，帰納的に解ける．すなわち，AR(p) モデルのパラメータを $(a_1^{(p)}, \ldots, a_p^{(p)}, \sigma_p^2)$ と書くと，次の関係式が成り立つ．

1. ラグ $p = 0$ のとき，$\sigma_0^2 = \gamma_0$
2. ラグ $p \geq 1$ のとき，行列 Γ_{p-1} は正則で，AR($p-1$) モデルのパラメータ $(a_1^{(p-1)}, \ldots, a_{p-1}^{(p-1)}, \sigma_{p-1}^2)$ が推定されているとする．このとき，行列 Γ_p も正則で，AR(p) モデルのパラメータ $(a_1^{(p)}, \ldots, a_p^{(p)}, \sigma_p^2)$ は次のように求められる．

$$a_p^{(p)} = \left(\gamma_p - \sum_{i=1}^{p-1} a_i^{(p-1)} \gamma_{p-i} \right) \sigma_{p-1}^{-2} \tag{2.2.1}$$

$$a_k^{(p)} = a_k^{(p-1)} - a_{p-k}^{(p-1)} a_p^{(p)} \ (k = 1, \ldots, p-1) \tag{2.2.2}$$

$$\sigma_p^2 = \left(1 - (a_p^{(p)})^2 \right) \sigma_{p-1}^2 \tag{2.2.3}$$

Proof. $p=0$ のとき，AR(0) モデルは

$$x_t = \varepsilon_t \sim W.N.(\sigma_0^2) \tag{2.2.4}$$

となるので，$\sigma_0^2 = \gamma_0$.
$p \geq 1$ のとき，行列 Γ_{p-1} が正則とせよ．AR$(p-1)$ モデルのパラメータはともに Yule-walker 方程式

$$\gamma_0 = \sum_{i=1}^{p-1} a_i^{(p-1)} \gamma_i + \sigma_{p-1}^2 \tag{2.2.5}$$

$$\begin{pmatrix} \gamma_1 \\ \vdots \\ \gamma_{p-1} \end{pmatrix} = \Gamma_{p-1} \begin{pmatrix} a_1^{(p-1)} \\ \vdots \\ a_{p-1}^{(p-1)} \end{pmatrix} \tag{2.2.6}$$

を満たす．同様に，AR(p) モデルのパラメータも Yule-walker 方程式

$$\gamma_0 = \sum_{i=1}^{p} a_i^{(p)} \gamma_i + \sigma_p^2 \tag{2.2.7}$$

$$\begin{pmatrix} \gamma_1 \\ \vdots \\ \gamma_p \end{pmatrix} = \Gamma_p \begin{pmatrix} a_1^{(p)} \\ \vdots \\ a_p^{(p)} \end{pmatrix} \tag{2.2.8}$$

を満たす．2 つ目の条件は，$p-1$ までの行と p の行を

$$\left(\begin{array}{c} \gamma_1 \\ \vdots \\ \gamma_{p-1} \\ \hline \gamma_p \end{array}\right) = \left(\begin{array}{ccc|c} & \Gamma_{p-1} & & \begin{matrix} \gamma_{p-1} \\ \vdots \\ \gamma_1 \end{matrix} \\ \hline \gamma_{p-1} & \cdots & \gamma_1 & \gamma_0 \end{array}\right) \left(\begin{array}{c} a_1^{(p)} \\ \vdots \\ a_{p-1}^{(p)} \\ \hline a_p^{(p)} \end{array}\right) \tag{2.2.9}$$

のようにブロック分けすると

$$\begin{pmatrix} \gamma_1 \\ \vdots \\ \gamma_{p-1} \end{pmatrix} = \Gamma_{p-1} \begin{pmatrix} a_1^{(p)} \\ \vdots \\ a_{p-1}^{(p)} \end{pmatrix} + \begin{pmatrix} \gamma_{p-1} \\ \vdots \\ \gamma_1 \end{pmatrix} a_p^{(p)} \tag{2.2.10}$$

$$\gamma_p = \sum_{i=1}^{p} a_i^{(p)} \gamma_{p-i} \tag{2.2.11}$$

のように，2 つの条件に分離できる．
まず，2 つ目の漸化式を示す．式 (2.2.10) の左辺と右辺第 2 項に式 (2.2.6) を代入すると

$$\Gamma_{p-1} \begin{pmatrix} a_1^{(p-1)} \\ \vdots \\ a_{p-1}^{(p-1)} \end{pmatrix} = \Gamma_{p-1} \begin{pmatrix} a_1^{(p)} \\ \vdots \\ a_{p-1}^{(p)} \end{pmatrix} + \Gamma_{p-1} \begin{pmatrix} a_{p-1}^{(p-1)} a_p^{(p)} \\ \vdots \\ a_1^{(p-1)} a_p^{(p)} \end{pmatrix} \tag{2.2.12}$$

が成り立つ．Γ_{p-1} が正則であることから

$$\begin{pmatrix} a_1^{(p-1)} \\ \vdots \\ a_{p-1}^{(p-1)} \end{pmatrix} = \begin{pmatrix} a_1^{(p)} \\ \vdots \\ a_{p-1}^{(p)} \end{pmatrix} + \begin{pmatrix} a_{p-1}^{(p-1)} a_p^{(p)} \\ \vdots \\ a_1^{(p-1)} a_p^{(p)} \end{pmatrix} \tag{2.2.13}$$

を得る．よって，右辺第 1 項について成分ごとに解くと

$$a_k^{(p)} = a_k^{(p-1)} - a_{p-k}^{(p-1)} a_p^{(p)} \ (k = 1, \ldots, p-1) \tag{2.2.14}$$

を得る．

次に，1 つ目の漸化式を示す．式 (2.2.11) にいま整理した式 (2.2.14) を代入する．

$$\begin{aligned} \gamma_p &= \sum_{i=1}^{p} a_i^{(p)} \gamma_{p-i} \\ &= \sum_{i=1}^{p-1} a_i^{(p)} \gamma_{p-i} + a_p^{(p)} \gamma_0 \\ &= \sum_{i=1}^{p-1} \left(a_k^{(p-1)} - a_{p-i}^{(p-1)} a_p^{(p)} \right) \gamma_{p-i} + a_p^{(p)} \gamma_0 \\ &= \sum_{i=1}^{p-1} a_k^{(p-1)} \gamma_{p-i} + \left(\gamma_0 - \sum_{i=1}^{p-1} a_{p-i}^{(p-1)} \gamma_{p-i} \right) a_p^{(p)} \\ &= \sum_{i=1}^{p-1} a_k^{(p-1)} \gamma_{p-i} + \left(\gamma_0 - \sum_{i=1}^{p-1} a_i^{(p-1)} \gamma_i \right) a_p^{(p)} \\ &= \sum_{i=1}^{p-1} a_k^{(p-1)} \gamma_{p-i} + \sigma_{p-1}^2 a_p^{(p)} \end{aligned} \tag{2.2.15}$$

最後の式変形で式 (2.2.5) を用いた．よって，右辺第 2 項を $a_p^{(p)}$ について解くと，

$$a_p^{(p)} = \left(\gamma_p - \sum_{i=1}^{p-1} a_i^{(p-1)} \gamma_{p-i} \right) \sigma_{p-1}^{-2} \tag{2.2.16}$$

を得る．また，以上の 2 つの結果から，AR(p) についての Yule-walker 方程式の第二条件の行列形がただ 1 組の解をもつことが確認できるので，Γ_p は正則である．

最後に，3 つ目の漸化式を示す．式 (2.2.7) を σ_p^2 について解く．

$$
\begin{aligned}
\sigma_p^2 &= \gamma_0 - \sum_{i=1}^{p} a_i^{(p)} \gamma_i \\
&= \gamma_0 - \sum_{i=1}^{p-1} \left(a_i^{(p-1)} - a_{p-i}^{(p-1)} a_p^{(p)} \right) \gamma_i - a_p^{(p)} \gamma_p \\
&= \gamma_0 - \sum_{i=1}^{p-1} a_i^{(p-1)} \gamma_i - a_p^{(p)} \left(\gamma_p - \sum_{i=1}^{p-1} a_{p-i}^{(p-1)} \gamma_i \right) \\
&= \gamma_0 - \sum_{i=1}^{p-1} a_i^{(p-1)} \gamma_i - a_p^{(p)} \left(\gamma_p - \sum_{i=1}^{p-1} a_i^{(p-1)} \gamma_{p-i} \right) \\
&= \sigma_{p-1}^2 - a_p^{(p)} \left(a_p^{(p)} \sigma_{p-1}^2 \right) \\
&= \left(1 - (a_p^{(p)})^2 \right) \sigma_{p-1}^2
\end{aligned}
\tag{2.2.17}
$$

2 つ目の式変形で式 (2.2.14)，5 つ目の式変形で式 (2.2.16) を用いた．

3　自己相関関数と偏自己相関関数

4　定常性検定

単位根検定と定常性検定はイコールでない．前者の代表例である ADF 検定は